Отчёт по заданию 3.2

а) Постановка задачи

Работа состоит из двух частей.

Часть 1. Исследовано поведение градиентного спуска и метода Ньютона на выпуклых квадратичных функциях с разной обусловленностью: построены траектории на фоне линий уровня, сравнено число итераций и характер сходимости при выбранной в коде стратегии шага (поиск Армихо/Вольфа либо фиксированный шаг — как в репозитории лаборатории).

Часть 2. Для двумерной функции Била реализован оракул с аналитическим градиентом и гессианом; построены линии уровня на области с оврагами и глобальной структурой; из нескольких начальных точек сравнены траектории градиентного спуска и Ньютона; построена карта бассейнов притяжения (сетка стартов, цвет — итоговая окрестность сходимости, отдельно отмечены случаи несходимости). В отчёте зафиксированы сходимость к окрестности глобального минимума Била $(3,\ 0.5)$ с $f^* = 0$ и ограничения Ньютона при неположительно определённом гессиане.

Ниже приведена формулировка задания из методических материалов.

3.2.1 Часть 1. Квадратичные функции (анализ обусловленности)

Рассматривается $f(x) = \frac{1}{2}\langle Ax, x\rangle - \langle b, x\rangle$, $A \in \mathbb{S}^n_{++}$, $b \in \mathbb{R}^n$. В коде используется `QuadraticOracle` из `oracles`.

1. Две двумерные квадратики: хорошо обусловленная ($\kappa \approx 1$, уровни близки к окружностям) и плохо обусловленная ($\kappa \gg 1$, вытянутые эллипсы).
2. Градиентный спуск и Ньютон из одной и той же точки x_0.
3. Контуры уровней и наложенные траектории обоих методов.

3.2.2 Часть 2. Невыпуклая функция (сложная геометрия)

У квадратичной формы один глобальный минимум; далее — невыпуклая 2D-функция по варианту (в данной работе — Била). От начального приближения зависит, к какой стационарной точке $\nabla f = 0$ придёт итерационный процесс.

1. Оракул с аналитическими ∇f и $\nabla^2 f$.
2. Линии уровня на интервале, где видны овраги, седла и/или несколько минимумов (если есть).
3. Траектории из 3–4 разных x_0 (овраг, крутой склон, окрестность локального экстремума или седла).
4. Карта бассейнов: сетка стартов (в методичке — до 200×200 на $[-5, 5]^2$), запуск из каждой ячейки; цвет — тип исхода (минимум; при Химмельблау — до четырёх минимумов); чёрный — несходимость или аварийное завершение; отдельный цвет — седло или локальный максимум.

Для уровней применялись `plot_levels`, для траекторий — `plot_trajectory` из `plot_trajectory_2d.py`; карты — `plt.imshow` / `plt.pcolormesh`.

3.2.3 Вопросы для отчёта

1. Как отличается поведение градиентного спуска в зависимости от числа обусловленности κ и стратегии выбора шага (константная, Армихо, Вульф)?
2. Как ведёт себя метод Ньютона на квадратичной функции по сравнению с градиентным спуском? За сколько итераций он сходится и почему?
3. Сошлись ли методы в один и тот же минимум на невыпуклой функции из разных стартовых точек? Встречалась ли ошибка разложения Холецкого / неположительно определённый гессиан (`LinAlgError` или `newton_direction_error` в коде) при Ньютоне? Если да — объяснить с точки зрения спектра матрицы Гессе, почему в этой точке классический Ньютон математически неприменим в исходном виде.
4. Почему градиентный спуск почти никогда не сходится к седловым точкам, даже если старт недалеко от них?
5. Почему «чистый» метод Ньютона (без модификации гессиана) может сходиться к седловым точкам или даже локальным максимумам? Как выглядят границы между бассейнами притяжения у Ньютона? Наблюдается ли «фрактальная» структура на границах (фракталы Ньютона)? (Дополнительно для трека с модификацией $H + \gamma I$: сравнить карту притяжения модифицированного Ньютона с исходной.)

Ответы

1. ГС, κ и шаг. Пусть $f(x) = \frac{1}{2}x^\top Ax - b^\top x$, $A \succ 0$, $\mu = \lambda_{\min}(A)$, $L = \lambda_{\max}(A)$, $\kappa = L/\mu$. Рост κ соответствует более вытянутым эллипсам уровня и узкому оврагу: градиент почти ортогонален направлению к минимуму, типичны зигзаги и рост числа итераций. На L-гладкой μ-сильно выпуклой квадратике ГС с $\alpha \in (0, 2/L)$ сходится линейно; при больших κ коэффициент линейного убывания близок к единице.
   Постоянный шаг: условие $0 < \alpha < 2/L$; иначе возможна расходимость, при слишком малом α — медленная сходимость; на плохо обусловленных примерах узкий диапазон допустимых α.
   Армихо: backtracking со спуском по f, устойчивость выше фиксированного шага без подбора, в узком овраге часто даёт мелкие шаги.
   Вульф: дополнительно ограничивает производную вдоль направления, шаги обычно крупнее, чем у «чистого» Армихо в тех же задачах; на квадратике часто быстрее одного лишь Армихо и стабильнее произвольной константы.
   В сумме: с ростом κ ГС замедляется; константный шаг наименее гибкий, Армихо даёт гарантированный спуск, Вульф — компромисс скорости и устойчивости.
2. Ньютон на квадратике. $\nabla f(x) = Ax - b$, $\nabla^2 f(x) = A$. Уравнение

$Ad_k = -(Ax_k - b)$ даёт $d_k = x^* - x_k$, $x^* = A^{-1}b$. При шаге $\alpha = 1$: $x_{k+1} = x^*$ — одна итерация до решения (при точном решении системы). Модель второго порядка совпадает с f, поэтому плохая обусловленность уровней для Ньютона не проявляется так, как для ГС (линейная сходимость с фактором, зависящим от κ). Если в реализации стоит line search и он даёт $\alpha < 1$, итераций может быть больше одной.

3. Била и ошибка направления. Из разных x_0 оба метода не обязаны приходить в один и тот же минимум или одну стационарную точку: бассейны различаются; Ньютон сильнее зависит от старта. Шаг в коде через разложение Холецкого для $H_k = \nabla^2 f(x_k)$ существует при симметричной положительно определённой H_k ($\lambda_i(H_k) > 0$). Если $\lambda_{\min}(H_k) \leq 0$ (седло, область «вершины» рельефа), H_k не SPD — в постановке минимизации классическое ньютоновское направление через $H_k^{-1} g_k$ некорректно; в программе это `LinAlgError` / `newton_direction_error`. По спектру H_k виден знак кривизны вдоль главных направлений; $\lambda_i < 0$ — направления с кривизной «вверх».

4. ГС и седла. В седле $\nabla f = 0$, но есть $\lambda(H) < 0$. Линеаризация $x_{k+1} = x_k - \alpha \nabla f(x_k)$ около седла: $x_{k+1} - x_s \approx (I - \alpha H_s)(x_k - x_s)$; для собственного вектора с $\lambda < 0$ множитель $1 - \alpha\lambda = 1 + \alpha|\lambda| > 1$, малые отклонения по этому направлению растут. Седло — неустойчивая неподвижная точка отображения спуска; начальные данные на устойчивом многообразии седла образуют множество меры ноль, поэтому для типичных стартов итерации уходят из окрестности седла.

5. Ньютон, седла, бассейны. Классический Ньютон ищет корни $\nabla f(x) = 0$, а не только минимумы; к любой невырожденной стационарной точке с обратимым H траектория может сойтись. Границы бассейнов Ньютона на картах часто изломаннее, чем у ГС: направление сильно зависит от $H^{-1}g$, около почти вырожденного H поведение резко меняется. На границах аттракторов на плоскости стартов иногда видна фракталоподобная структура (в литературе — «фракталы Ньютона»). Замена H на $H + \gamma I$, $\gamma > 0$, сдвигает спектр: $\lambda_i(H + \gamma I) = \lambda_i(H) + \gamma$, матрица SPD, реже срывы Холецкого и сходимость к не-минимальным стационарным точкам; картина бассейнов может стать глаже и ближе к картине ГС.

б) Оптимизируемые функции, данные, оборудование, методы и параметры

Функции

1. Квадратичная форма $f(x) = \frac{1}{2}x^\top Ax - b^\top x$, $A \succ 0$. Взяты два варианта спектра A: малое $\kappa = \lambda_{\max}/\lambda_{\min}$ и большое κ. Матрица A и вектор b заданы синтетически (без датасетов).

2. Функция Била:
$f(x, y) = (1{,}5 - x + xy)^2 + (2{,}25 - x + xy^2)^2 + (2{,}625 - x + xy^3)^2$.

Глобальный минимум $(3,\ 0{,}5)$, $f^* = 0$. Оракул считает f, ∇f, $\nabla^2 f$ по формулам. Размерность $n = 2$.

Оборудование

16 ГБ ОЗУ, Intel Core i3, дискретная видеокарта не использовалась.

Методы и параметры

- Градиентный спуск и метод Ньютона из модуля оптимизации курса.
- Останов: относительное условие на $\|g_k\|^2$ к $\|g_0\|^2$ с ε порядка 10^{-8}–10^{-10}, плюс `max_iter` (для Била — порядка тысяч итераций у ГС и сотен у Ньютона, конкретные значения — в зафиксированном запуске ноутбука).
- Линейный поиск: Вульф или Армихо с $c_1 = 10^{-4}$, для Вульфа $c_2 = 0.9$, стартовый α_0; для Ньютона при необходимости уменьшался базовый α_0 в линейном поиске, чтобы реже выходить на `computational_error` при срыве backtracking.
- Бассейны: сетка на квадрате (в работе — как на рис. 5, типично $[-5, 5]^2$), из каждой ячейки один прогон; цвет — класс исхода (окрестность $(3, 0{,}5)$, иной минимум/стационарная точка, несходимость).

в) Результаты эксперимента

Выпуклая квадратичная функция

Рис. 1. Линии уровня и траектории ГС и Ньютона для хорошо и плохо обусловленной квадратики (четыре панели: два варианта A и два метода / сценарий из ноутбука). Оси: x_1, x_2.

При малом κ траектория ГС близка к прямой к минимуму; при большом κ контуры вытянуты, у ГС зигзаги вдоль оврага и больше итераций. Ньютон при SPD-гессиане доходит до решения за малое число шагов; на плоскости траектория близка к отрезку к центру семейства эллипсов.

Функция Била

Рис. 2. Уровни f на выбранной области. Оси: x, y.

Рельеф невыпуклый; глобальный минимум у $(3,\ 0{,}5)$; вытянутые участки влияют на выбор траектории.

Рис. 3. Траектории ГС из нескольких стартов на фоне уровней. Оси: x_1, x_2; на графике отмечены старт и конец итераций.

В зависимости от x_0 конечная точка оказывается в окрестности глобального минимума или алгоритм останавливается по относительному критерию по

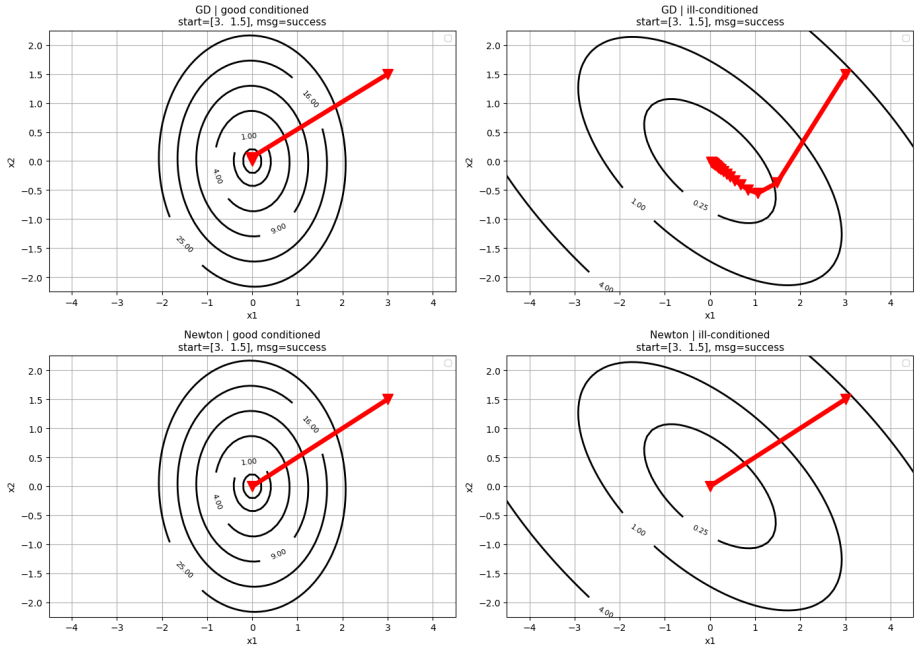

Figure 1: Рис. 1. Квадратичная задача: GD и Ньютон, хорошо/плохо обусловленные варианты.

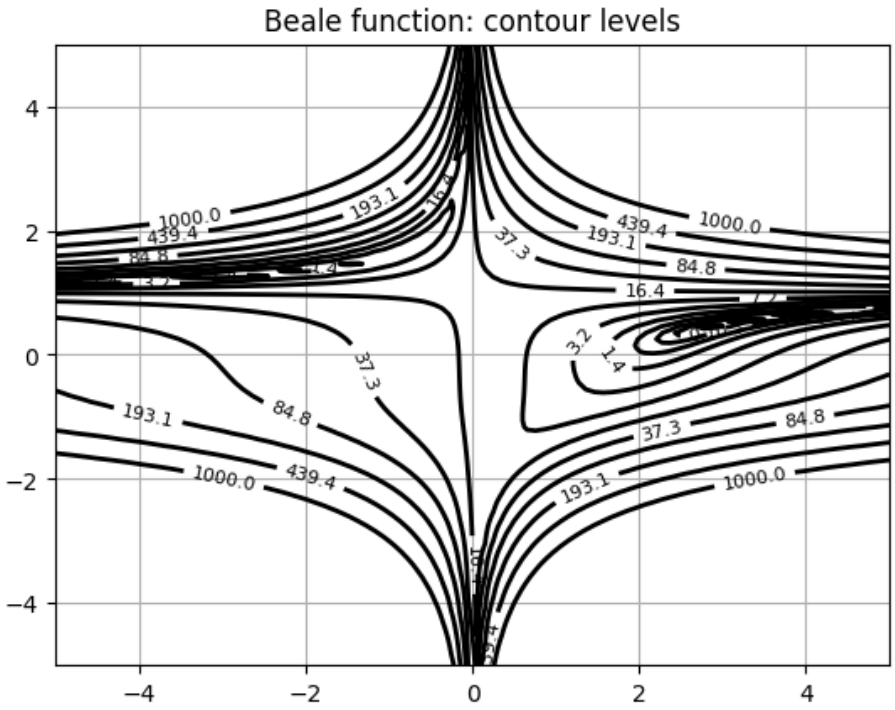

Figure 2: Рис. 2. Линии уровня функции Била.

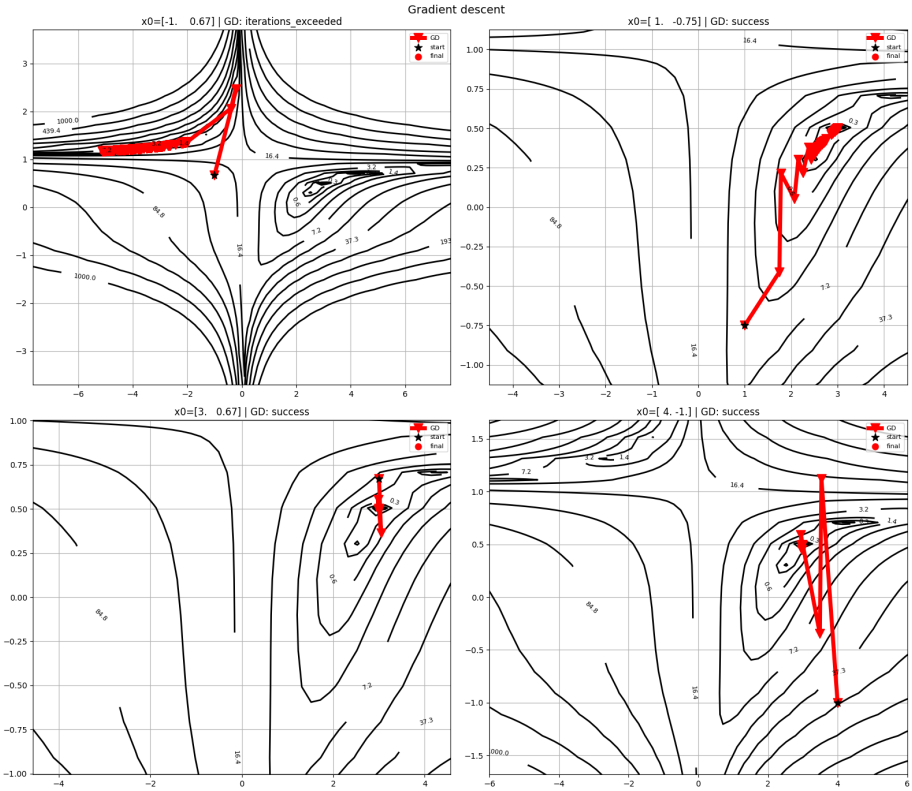

Figure 3: Рис. 3. Функция Била: градиентный спуск.

градиенту при ещё заметном f; сопоставление — по полю «message»/статусу в выводе оптимизатора и по значению f в конечной точке.

Рис. 4. Траектории Ньютона для того же набора стартов.

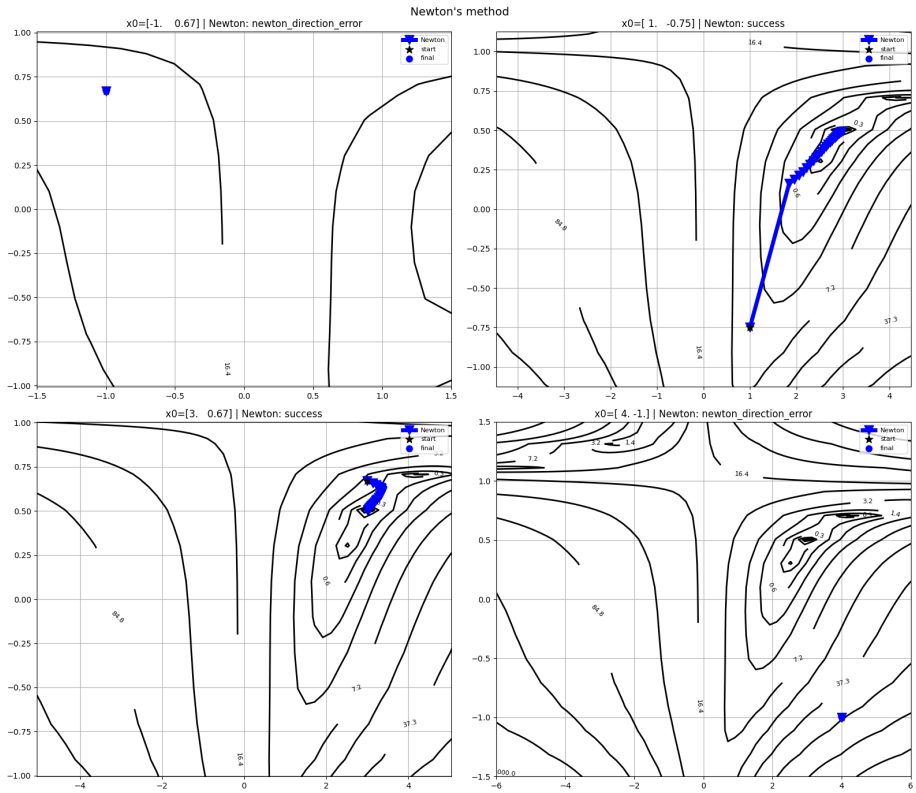

Figure 4: Рис. 4. Функция Била: метод Ньютона.

Фиксировались остановки с `newton_direction_error` (гессиан не PD, разложение Холецкого не строится) и случаи срыва линейного поиска; по сравнению с выпуклой квадратикой поведение менее предсказуемо.

Рис. 5. Карта бассейнов: из каждой ячейки сетки — запуск метода; цвет — класс исхода (окрестность $(3,\ 0{,}5)$, иной исход, несходимость). По подписям на файле рисунка — ГС и/или Ньютон.

Оси соответствуют координатам старта; расшифровка классов — по легенде на рисунке. Карта показывает разбиение плоскости x_0 по итогу прогона при зафиксированных параметрах метода.

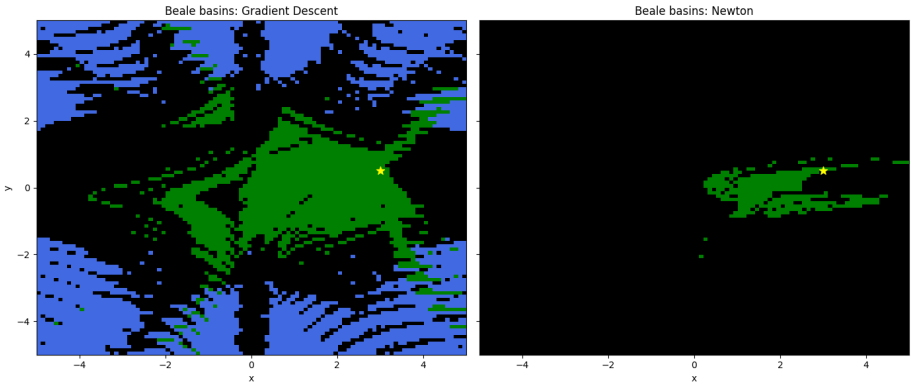

Figure 5: Рис. 5. Карта бассейнов (GD и Ньютон по подписям на рисунке).

г) Выводы и связь с теорией

1. Квадратичная задача. Скорость ГС на μ-сильно выпуклых L-гладких функциях теоретически ограничена $\kappa = L/\mu$; при больших κ длинные почти ортогональные к направлению к минимуму участки траектории. Ньютон с точным гессианом на строго выпуклой квадратике за один полный шаг даёт решение — на чертеже это согласуется с короткой почти прямой траекторией к центру эллипсов; это частный случай интерпретации Ньютона как метода второго порядка, подбирающего локальный масштаб через H^{-1}.

2. Била. Глобально невыпуклая функция с различными локальными режимами (овраги, пологие зоны); бассейны притяжения одного и того же метода для разных стартов не совпадают. В эксперименте ГС с линейным поиском обходился без систематического обращения к разложению Холецкого; Ньютон чаще сталкивался с неопределённым гессианом и с необходимостью мелких шагов.

3. Относительный критерий останова. Условие $\|g_k\|^2 \leq \varepsilon\|g_0\|^2$ при большой $\|g_0\|$ допускает остаточную норму градиента, существенную в абсолютном масштабе, поэтому статус успешного завершения в логе не всегда совпадает с малой величиной f относительно f^*. При построении бассейнов и текстовых выводов дополнительно использовались $f(x_{\text{end}})$ и расстояние до $(3, 0{,}5)$.

4. Ньютон и полный шаг. В окрестности решения на выпуклых задачах с SPD-гессианом шаг $\alpha = 1$ часто удовлетворяет условиям Вольфа/Армихо и даёт квадратичную сходимость по норме градиента; на Била вдали от минимума направление и величина шага нередко мешают быстрому входу в эту фазу — согласуется с локальной, а не глобальной сходимостью классического Ньютона.

Эксперимент 3.3

Задача

Проанализировать зависимость кол-ва итераций градиентного спуска от обучловленности (k) и размерности (n) задачи.

Функции

Квадратичная функция:

$f(x) = x^T Ax - b^T x$

Данные

Нет, точка $x_0 = 0_n$

Железо

CPU: Intel i5-12700H

Метод

Градиентный спуск

tolerance = 1e-10
max_iter = 5000

Результаты

С ростом k, кол-во итераций растет линейно.

С ростом n, кол-во итераций не изменяется.

Графики зависимости кол-ва итераций от k

Жирным отмечена среднее количество.

Сравнение кол-ва итераций для разных n

Оправдание

На лекции была формула

$f(x_k) - f_0 \leq (1 - \mu/L)^k (f(x_0) - f_0)$

для нашей функции

$\mu = \lambda_1 = 1, L = \lambda_n = k$

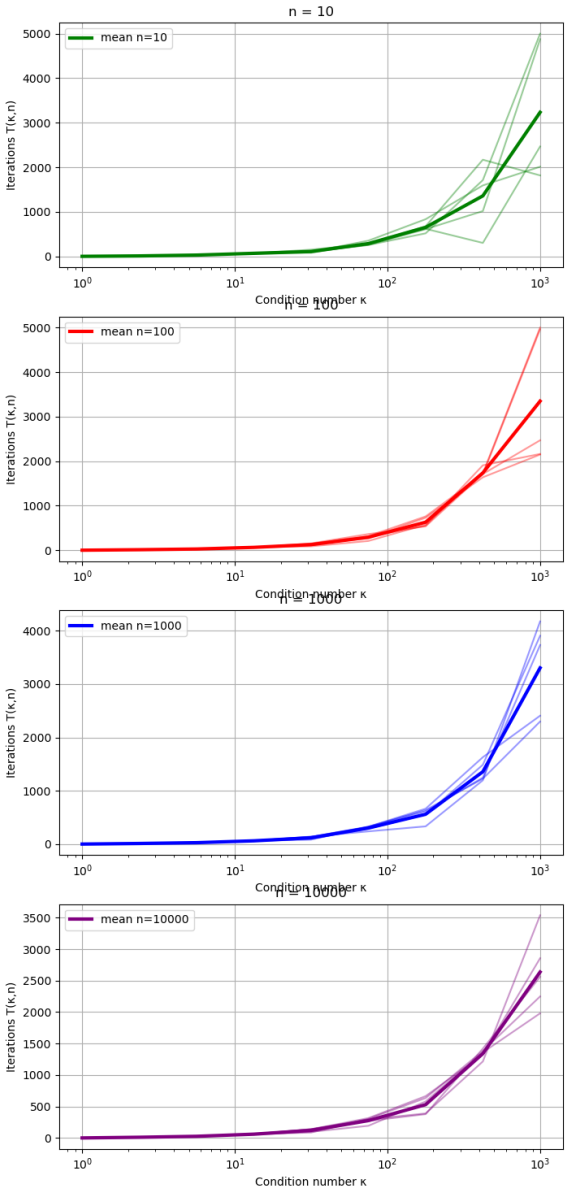

Figure 6: Alt text

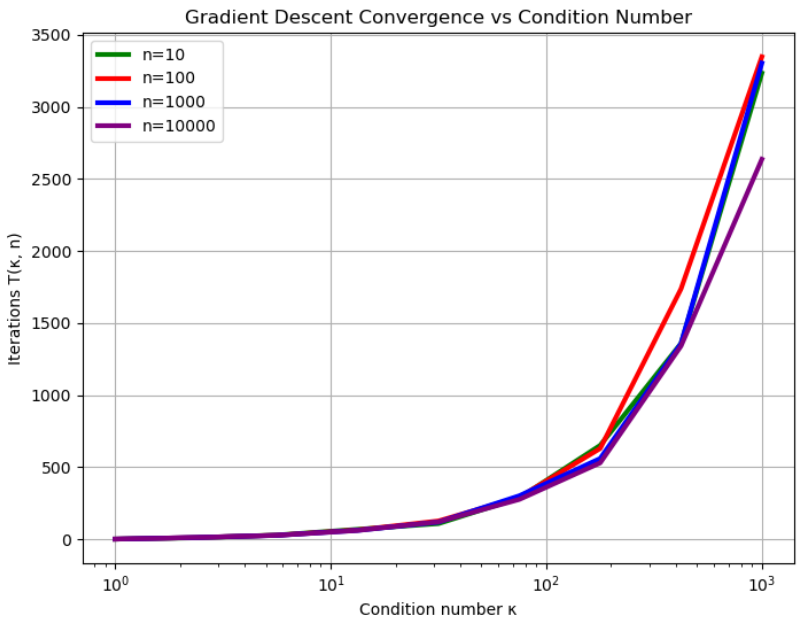

Figure 7: Alt text

то $\lambda \to +\inf$, получаем, что скобка стремится к 1 и соответственно скорость становится очень медленной.

Эксперимент 3.4. Сравнение градиентного спуска и метода Ньютона на реальных задачах машинного обучения

а) Постановка задачи

Рассматривается безусловная минимизация гладкой функции

$$f(x) = \frac{1}{m}\sum_{i=1}^{m} \ell((Ax)_i, y_i) + \frac{\lambda}{2}\|x\|_2^2,$$

где $A \in \mathbb{R}^{m\times n}$ — матрица признаков (в общем случае разреженная, CSR), $y \in \mathbb{R}^m$ — вектор меток, ℓ — потеря по типу задачи.

Пакет 1 (п. 5.2.1 методички):

- Регрессия — потеря Log-Cosh;
- Классификация — экспоненциальная потеря (AdaBoost), метки приведены к $\{-1, +1\}$.

Условия эксперимента:

- регуляризация $\lambda = 1/m$;
- старт $x_0 = 0$;
- линейный поиск: сильные условия Вольфа с $c_1 = 10^{-4}$, $c_2 = 0{,}9$ (при неудаче — Армихо), см. реализацию `LineSearchTool`;
- критерий остановки: $\|\nabla f(x_k)\|_2^2 \le \varepsilon\,\|\nabla f(x_0)\|_2^2$, $\varepsilon = 10^{-5}$.

б) Целевые функции, данные, аппаратура, параметры и оценка сложности

Датасеты и размерности

Файл	m	n	nnz	nnz/(mn)
`abalone_scale`	4177	8	32080	≈ 0,96
`bodyfat_scale`	252	14	3528	1
`a9a`	32561	123	451592	≈ 0,11
`gisette_scale.bz2`	6000	5000	≈ 2,97·10□	≈ 0,99

Для gisette использована полная размерность 6000×5000 из файла LIBSVM; матрица почти плотная, поэтому шаг наивного Ньютона с явным

плотным Гессианом имеет высокую стоимость $O(n^3)$ на факторизацию. Для ускорения прогона в скрипте/ноутбуке можно задать срез столбцов (`--gisette-max-features N` или `GISETTE_MAX_FEATURES`).

Аппаратура (фактический прогон, см. `experiment_3_4_meta.json`)

- ОС: Windows 10/11;
- CPU: Intel, Family 6 Model 154 (12-е поколение);
- Python 3.12, NumPy/SciPy; вычисления на CPU, без GPU.

Стоимость итерации и память, $O(\cdot)$

Пусть $\texttt{nnz}$ — число ненулевых элементов A.

Градиентный спуск

- Один градиент: вычисления Ax и $A^\top u$ — $O(\texttt{nnz})$ при CSR.
- Шаг с линейным поиском: несколько оценок f вдоль луча, каждая того же порядка по $\texttt{nnz}$ → время итерации $O(\texttt{nnz})$ (с константой, зависящей от числа попыток шага).
- Память: $O(\texttt{nnz} + m + n)$.

Метод Ньютона (явный Гессиан + Холецкий)

- Формирование $H = A^\top DA + \lambda I$ в худшем случае даёт плотную матрицу $n \times n$: порядок $O(\texttt{nnz} \cdot n)$ на умножения/накопление, плюс $O(n^3)$ на Холецкий, $O(n^2)$ памяти на H.
- Итого время итерации: $O(\texttt{nnz} \cdot n + n^3)$; память: $O(\texttt{nnz} + n^2)$ (плюс вспомогательные векторы $O(m + n)$).

в) Результаты

На каждом датасете построены два графика (ГС и Ньютон на одних осях):

1. $f(x_k)$ от настенного времени (с), вертикальная ось — логарифмическая.
2. $\|\nabla f(x_k)\|_2^2 / \|\nabla f(x_0)\|_2^2$ от времени (с), вертикальная ось — логарифмическая.

Файлы графиков (PDF):

Датасет	f vs время	Норма градиента vs время
abalone	`figures/exp34_abalone_f_time.pdf`	`figures/exp34_abalone_scale_grad_time.pdf`
bodyfat	`figures/exp34_bodyfat_f_time.pdf`	`figures/exp34_bodyfat_scale_grad_time.pdf`
a9a	`figures/exp34_a9a_f_time.pdf`	`figures/exp34_a9a_grad_time.pdf`
gisette	`figures/exp34_gisette_f_time.pdf`	`figures/exp34_gisette_scale_bz2_grad_time.pdf`

Комментарии к графикам

- abalone / bodyfat (малые n): на графике $f(t)$ кривая Ньютона быстро уходит вниз: мало итераций при малой стоимости одного шага. На графике

относительной нормы градиента у Ньютона виден резкий спад за короткое время (на лог-масштабе — почти «вертикальный» участок).

- a9a: качественно та же картина: Ньютон достигает критерия за считанные итерации и меньшее настенное время, чем ГС, несмотря на более дорогой шаг.
- gisette (полный $n = 5000$): шаг Ньютона дорогой (n^3); кривые показывают компромисс между числом итераций ГС и стоимостью одной итерации Ньютона. В представленном прогоне суммарное время Ньютона оказалось больше, чем у ГС

Итерации и настенное время

Датасет	Итераций ГС	Время ГС, с	Итераций Ньютона	Время Ньютона, с
abalone_scale	142	0,35	4	0,02
bodyfat_scale	79	0,04	2	<0,01
a9a	178	1,73	4	0,15
gisette_scale.bz2	1874	1576,9	6	2320,2

г) Выводы и связь с теорией

1. Малые и умеренные n (abalone, bodyfat, a9a): метод Ньютона использует информацию о кривизне и даёт мало итераций; локально ожидаема квадратичная (суперлинейная) сходимость около минимума — на графике нормы градиента это проявляется как быстрый спад за короткое время. Суммарное настенное время до того же критерия в этих экспериментах у Ньютона меньше, чем у ГС.

2. Градиентный спуск при сильной выпуклости и удачном line search демонстрирует линейную (геометрическую) скорость убывания ошибки по итерациям; на лог-графике $\|\nabla f\|^2$ от времени это часто выглядит как более пологий, почти прямолинейный участок на длинном интервале итераций.

3. Большие n и почти плотная матрица (gisette): доминирует $O(n^3)$ на факторизацию Гессиана при наивной реализации Ньютона. В табл. 2 видно: 6 итераций Ньютона заняли больше времени, чем 1874 итерации ГС — каждая ньютоновская итерация на порядки тяжелее одной итерации ГС ($O(\texttt{nnz})$ при $\texttt{nnz} \approx mn$). Это согласуется с лекционными оценками: наивный Ньютон в высокой размерности на полных данных плохо масштабируется по времени, даже если число итераций мало.

4. Практический вывод: для задач типа полного gisette на CPU разумнее стохастический/батчевый ГС, квазиньютоновские методы или приближённые ньютоновские схемы без явного плотного H размера $n \times n$.

Отчёт по заданию 3.5

а) Постановка задачи

Исследовано влияние стратегии выбора длины шага в градиентном спуске на скорость и устойчивость сходимости. Сравнивались:

- константный шаг (`Constant`) при нескольких значениях шага;
- бэктрэкинг по правилу Армихо (`Armijo`) при разных c_1;
- линейный поиск по условиям Вольфа (`Wolfe`) при разных c_2 при фиксированном c_1.

Для каждой из двух постановок из одной и той же начальной точки (и для дополнительной второй точки) запускался один и тот же оптимизатор с разными опциями линейного поиска. Для квадратичной задачи на графиках — относительная невязка по значению функции в логарифмической шкале по итерациям; для ML-оракула — относительный квадрат нормы градиента $\|g_k\|^2/\|g_0\|^2$ в логарифмической шкале.

Ниже — формулировка из методических материалов (п. 3.5).

3.5 Эксперимент: стратегия выбора длины шага в градиентном спуске

Исследовать, как зависит поведение метода от стратегии подбора шага: константный шаг (попробовать различные значения), бэктрэкинг (попробовать различные константы c_1), условия Вульфа (попробовать различные параметры c_2). Рассмотреть квадратичную функцию и ML-модель варианта.

Запустить для этих функций градиентный спуск с разными стратегиями выбора шага из одной и той же начальной точки. Нарисовать кривые сходимости (для квадратичной — относительная невязка по функции в логарифмической шкале против числа итераций; для ML-оракула — относительный квадрат нормы градиента в логарифмической шкале против числа итераций) для разных стратегий на одном графике. Попробовать разные начальные точки.

Вопрос задания: какая стратегия выбора шага самая лучшая?

Ответ Универсально «лучшей» стратегии нет: она зависит от задачи (обусловленность, масштаб градиента), допустимого шага и критерия останова. В проведённых прогонах:

- на плохо обусловленной квадратике ($\kappa = 10^3$, $n = 40$) константные шаги 10^{-4} и $5 \cdot 10^{-4}$ за отведённое число итераций не достигли заданной точности; Вольф с $c_2 = 0.9$ давал наименьшее число итераций до относительной невязки по f порядка 10^{-8} для старта из нуля (таблично — ощутимо быстрее Армихо); для старта $x_0 = \mathbf{1}$ быстрее других линейных стратегий оказался тот же Wolfe $c_2 = 0.9$ (по числу итераций до успешного останова по градиенту), тогда как константный шаг снова упёрся в лимит `max_iter`;

- на Log-Cosh + L_2 синтетическая постановка с выбранными малыми константными шагами не достигла порога 10^{-8} по относительному $\|g\|^2$ за `max_iter`; Армихо и Вольф сошлись; по числу итераций до этого порога чуть выигрывал Wolfe с $c_2 = 0.1$ по сравнению с $c_2 = 0.9$, разница порядка нескольких итераций.

Итог: в данных экспериментах адаптивный линейный поиск (Армихо или Вольф) существенно надёжнее и быстрее фиксированного шага при тех же начальных условиях; среди Вольфа выбор c_2 влияет на длину шага (более жёсткое условие на кривизну по лучу при меньшем c_2 иногда ускоряет выход на малый градиент в гладкой выпуклой ML-постановке).

б) Оптимизируемые функции, данные, оборудование, методы и параметры

Функции и данные

1. Квадратичная форма $f(x) = \frac{1}{2}x^\top Ax - b^\top x$, $A \succ 0$. Размерность $n = 40$; спектр задавался геометрической прогрессией собственных чисел от 1 до 10^3 (число обусловленности $\kappa = 10^3$), ортогональное преобразование Q из случайной матрицы (`np.random.seed(42)`), вектор b — стандартный гауссов. Минимум $x^* = A^{-1}b$, на графике — отношение $(f(x_k) - f^*)/(f(x_0) - f^*)$.
2. Log-Cosh с L_2-регуляризацией (`LogCoshL2Oracle`): модель $y \approx Xw$, потери $\frac{1}{m}\sum_i \log\cosh\big((Xw-y)_i\big) + \frac{\lambda}{2}\|w\|^2$. Синтетика: $m = 1200$, $n = 40$, X, w_{true}, шум $\mathcal{N}(0,\ 0.2^2)$, $\lambda = 10^{-2}$, тот же seed 42.

Оборудование

16 ГБ ОЗУ, Intel Core i3, дискретная видеокарта не использовалась.

Методы и параметры

- Градиентный спуск из `src.optimization` с трассировкой истории.
- Квадратичная задача: `tolerance=$10^{-10}$`, `max_iter=7000`. Стратегии: `Const` $c \in \{10^{-4},\ 5\cdot 10^{-4}\}$; `Armijo` $c_1 \in \{10^{-4},\ 10^{-2}\}$, `alpha_0=1$`; Wolfe‘ $c_1 = 10^{-4}$, $c_2 \in \{0.1,\ 0.9\}$. Старты: $x_0 = 0$, $x_0 = \mathbf{1}$.
- ML: `tolerance=$10^{-8}$`, `max_iter=5000`. `Const` $c \in \{10^{-3},\ 3\cdot 10^{-3}\}$; `Armijo` и `Wolfe` — те же типичные c_1, c_2; старты: $w_0 = 0$, $w_0 = 2\mathbf{1}$.
- Графики сохранены в `figs/task_5/` (см. подписи к рисункам).

в) Результаты эксперимента

Квадратичная функция

Рис. 1. Относительная невязка $(f(x_k) - f^*)/(f(x_0) - f^*)$ в зависимости от итерации; старт $x_0 = 0$. Ось ординат — логарифмическая.

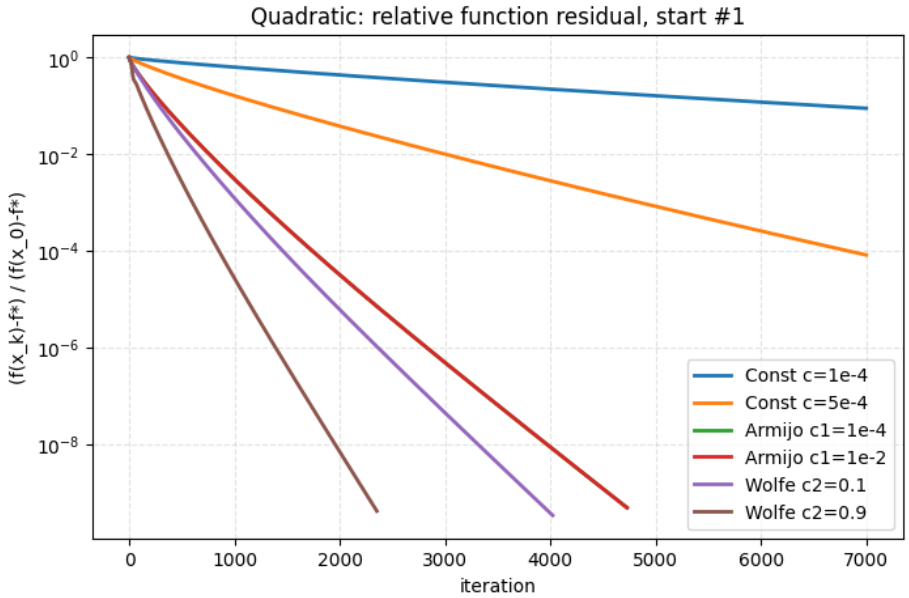

Figure 8: Рис. 1. Квадратичная задача, старт #1.

Для данных константных шагов кривые за 7000 итераций остаются выше порога; кривые Армихо и Вольфа монотонно убывают; Wolfe $c_2 = 0.9$ — наименьшее число итераций до успешного останова по градиенту среди сравниваемых методов (2352 против 4022 у Wolfe $c_2 = 0.1$ и 4728 у Армихо); относительная невязка по f падает ниже 10^{-8} заметно раньше финального шага (в протоколе ноутбука — около 1955-й итерации).

Рис. 2. Те же стратегии, старт $x_0 = \mathbf{1}$.

Паттерн тот же: константный шаг не укладывается в лимит итераций; наименьшее число итераций до `success` среди сходящихся — у Wolfe $c_2 = 0.9$ (1209 против 2479 у $c_2 = 0.1$ и ≈ 2400 у Армихо).

ML-оракул (Log-Cosh + L_2)

Рис. 3. Относительный квадрат нормы градиента, старт $w_0 = 0$, полный диапазон итераций.

Константные шаги практически не продвигаются к порогу по $\|g\|^2/\|g_0\|^2$;

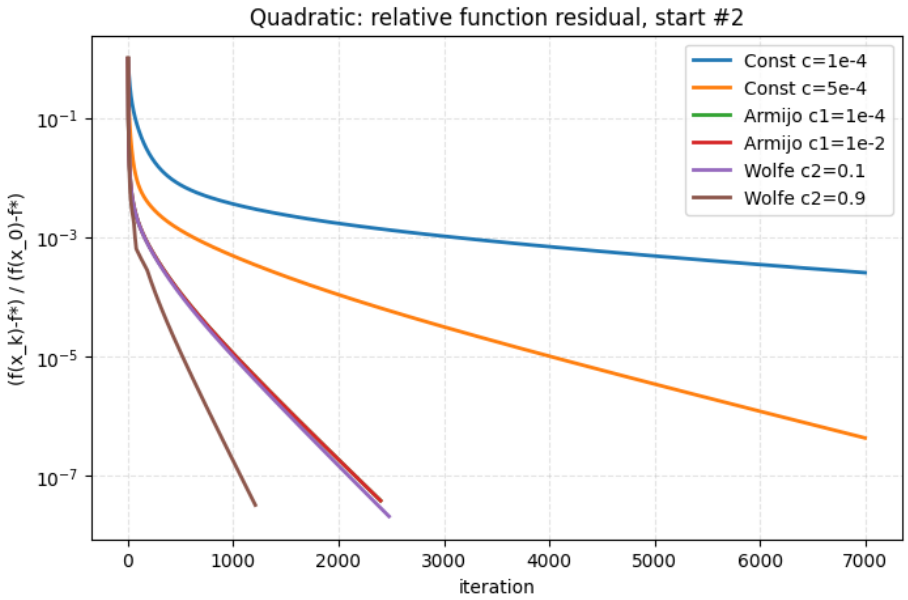

Figure 9: Рис. 2. Квадратичная задача, старт #2.

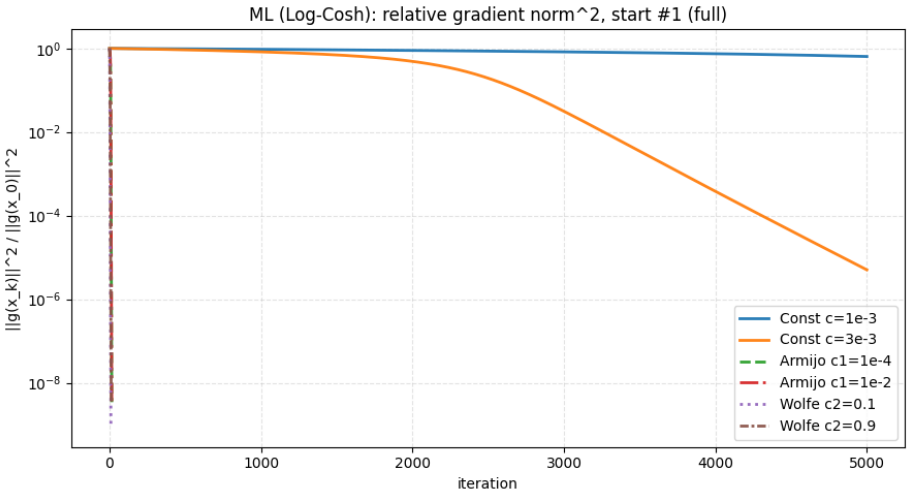

Figure 10: Рис. 3. Log-Cosh: полный график, старт #1.

линейный поиск даёт быстрый спуск.

Рис. 4. Фрагмент по итерациям $0 \dots 80$ для стартов с адаптивным поиском (без константных кривых), старт $w_0 = 0$.

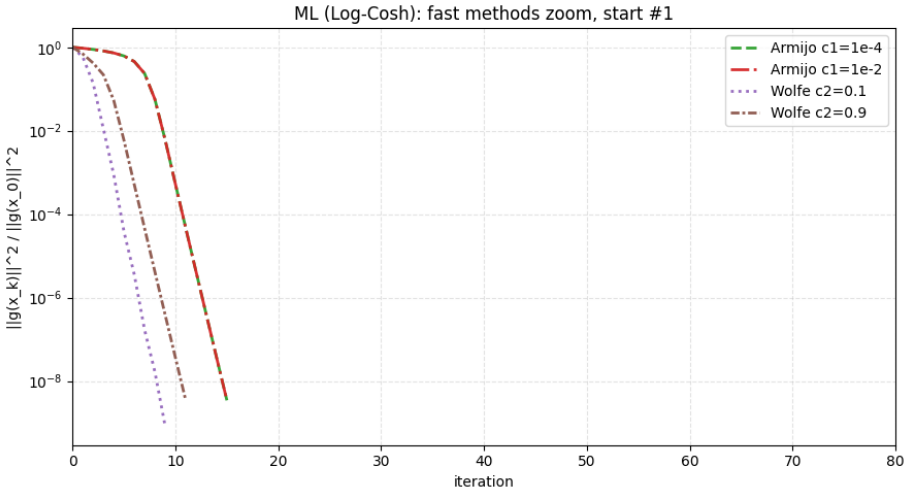

Figure 11: Рис. 4. Log-Cosh: укрупнение «быстрых» методов, старт #1.

По достижению $\|g_k\|^2/\|g_0\|^2 \leq 10^{-8}$ первым оказывается Wolfe $c_2 = 0.1$ (9-я итерация против 11-й у $c_2 = 0.9$; Армихо — 15 шагов).

Рис. 5–6. Аналогично для старта $w_0 = 2\mathbf{1}$: полный график и укрупнение.

Для второго старта снова Wolfe $c_2 = 0.1$ быстрее доводит относительный квадрат нормы градиента до 10^{-8} (10 против 13 итераций у $c_2 = 0.9$, 24 у Армихо).

г) Выводы и связь с теорией

1. Константный шаг на плохо обусловленной квадратике и на рассмотренной ML-задаче с выбранными значениями либо слишком консервативен (медленный прогресс), либо влек бы риск расходимости при завышении — без подбора под L константная стратегия проигрывает адаптивной. Теория для L-гладкой выпуклой функции требует $\alpha < 2/L$; на практике L может быть велико и неизвестно.

2. Армихо гарантирует достаточное убывание по f и устойчив, но дробление шага в овраге у квадратики здесь приводит к большему числу итераций, чем у Вольфа с «мягким» $c_2 = 0.9$.

3. Условия Вольфа добавляют контроль наклона вдоль направления спуска; при большем c_2 допускаются более длинные шаги, что на квадратике сократило число итераций. На гладкой выпуклой Log-Cosh+ridge

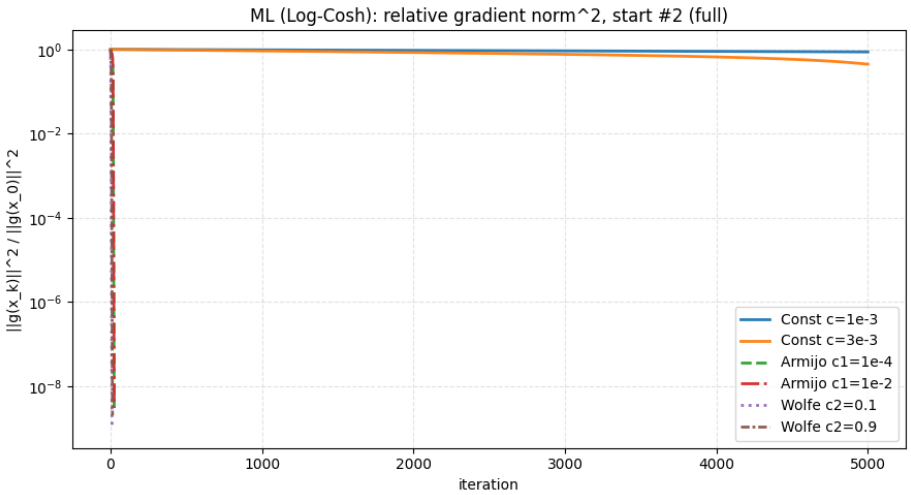

Figure 12: Рис. 5. Log-Cosh: полный график, старт #2.

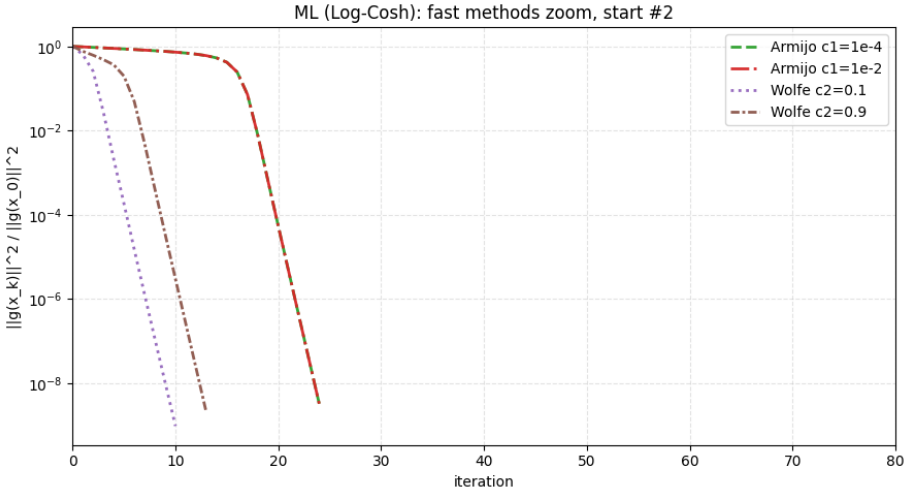

Figure 13: Рис. 6. Log-Cosh: укрупнение, старт #2.

постановке меньшее c_2 в эксперименте дало чуть более короткий путь до малого относительного градиента — согласуется с тем, что более жёсткое условие по кривизне может отсекать слишком длинные шаги и иногда лучше балансирует длину шага в начале.

4. Обобщая ответ на вопрос задания: оптимальная стратегия не одна; в работе надежнее всего оказались Армихо и Вольф; Вольф при настроенных c_1, c_2 давал наименьшее число итераций среди сравниваемых вариантов на обеих задачах, конкретный выбор c_2 зависел от постановки (квадратика — выигрыш $c_2 = 0.9$, Log-Cosh — небольшой выигрыш $c_2 = 0.1$).

Отчёт по заданию 3.6

а) Постановка задачи

Повторён эксперимент по сравнению стратегий выбора шага (как в п. 3.5 для ML), но для метода Ньютона на той же постановке: оракул Log-Cosh с L_2-регуляризацией, синтетические данные. Сравнивались константный шаг, Армихо и Вольф с теми же типами настройки параметров. Для каждой стратегии строились кривые относительного квадрата нормы градиента $\|g_k\|^2/\|g_0\|^2$ в логарифмической шкале; дополнительно по истории `alpha` фиксировался индекс итерации, начиная с которого все последующие выбранные шаги совпадают с единицей (в пределах численного допуска), и значения $\|\nabla f\|$ до/после этого перехода.

Ниже — формулировка из методических материалов (п. 3.6).

3.6 Эксперимент: стратегия выбора длины шага в методе Ньютона

Повторить эксперимент 3.5 со сравнением стратегий выбора шага на ML-моделях варианта, но для метода Ньютона. Какая стратегия работает лучше всего? Почему для метода Ньютона единичный шаг является приоритетным? Зафиксировать момент, когда алгоритм входит в зону квадратичной сходимости (шаг $\alpha = 1$ начинает приниматься всегда). Как меняется значение ∇f на этом этапе?

Вопросы задания и ответы

Какая стратегия работает лучше всего? В выполненных прогонах наиболее экономичны по числу итераций до критерия останова стратегии Вольфа: около 4–5 итераций против $\approx$ 102–103 у Армихо при одинаковых `max_iter` и допуске. Константный шаг $\alpha \in \{0.2, 0.5, 1\}$ не привёл к сходимости за 400 итераций (`iterations_exceeded`). Среди Вольфа с $c_1 = 10^{-4}$ вариант с $c_2 = 0.1$ слегка уменьшил число итераций относительно $c_2 = 0.9$.

Почему единичный шаг приоритетен? Ньютоновское направление d_k построено так, что при полном шаге $\alpha = 1$ следующая точка минимизирует квадратичную модель цели в x_k. В окрестности точки, где гессиан положительно

определён и цель близка к этой модели, шаг $\alpha = 1$ удовлетворяет условиям достаточного убывания и (сильным) Вольфа, после чего теоретически включается квадратичная сходимость по норме градиента. Линейный поиск с приоритетом пробовать $\alpha = 1$ реализует именно эту «естественную» длину шага классического Ньютона.

Момент входа в зону $\alpha_k = 1$ и поведение ∇f. Для Вольфа индекс k, начиная с которого все последующие α равны 1, оказался равным 1 для старта $w_0 = 0$ и 2 для старта $w_0 = 2\mathbf{1}$. В протоколе ноутбука при первом «стабильном» полном шаге: для старта 1 и Wolfe $c_2 = 0.1$ норма градиента до шага $\approx$ 0,18, после — $\approx$ 0,014; для $c_2 = 0.9$ — $\approx$ 0,43 и $\approx$ 0,32. Для старта 2: $c_2 = 0{,}1$ — $\approx$ 0,024 и $\approx 4 \cdot 10^{-5}$; $c_2 = 0{,}9$ — $\approx$ 0,18 и $\approx$ 0,011. То есть на переходе к режиму постоянных единичных шагов норма градиента заметно падает; при более «удачной» комбинации параметров и старта снижение оказывается на порядки. У Армихо условие «все последующие $\alpha = 1$» в данных прогонах не выполнилось (индекс в протоколе — `None`), что согласуется с более частым дроблением шага на фазе далеко от минимума.

б) Оптимизируемые функции, данные, оборудование, методы и параметры

Функция и данные

Log-Cosh с L_2-регуляризацией (`LogCoshL2Oracle`): $y \approx Xw$, целевая функция — среднее log cosh невязок плюс $\frac{\lambda}{2}\|w\|^2$. Синтетика: $m = 1200$, $n = 40$, матрица X и вектор истинных весов — гауссовы, шум отклика $\mathcal{N}(0,\, 0.2^2)$, $\lambda = 10^{-2}$, `np.random.seed(42)`.

Оборудование

16 ГБ ОЗУ, Intel Core i3, дискретная видеокарта не использовалась.

Методы и параметры

- Метод Ньютона из `src.optimization` (`newton`) с трассировкой истории и записью шагов `alpha` в историю.
- Критерий останова: относительное условие на квадрат нормы градиента с `tolerance=$10^{-12}$` (в коде ноутбука), `max_iter=400`.
- Стратегии линейного поиска: `Constant` с $c \in \{1.0,\, 0.5,\, 0.2\}$; `Armijo` с $c_1 \in \{10^{-4},\, 10^{-2}\}$, `alpha_0=1$`; Wolfe‘ с $c_1 = 10^{-4}$, $c_2 \in \{0.1,\, 0.9\}$.
- Начальные точки: $w_0 = 0$ и $w_0 = 2\mathbf{1}$.
- Графики сохранены в `figs/task_6/`.

в) Результаты эксперимента

Старт $w_0 = 0$

Рис. 1. Относительная величина $\|g_k\|^2/\|g_0\|^2$ по итерациям, все стратегии (полный диапазон).

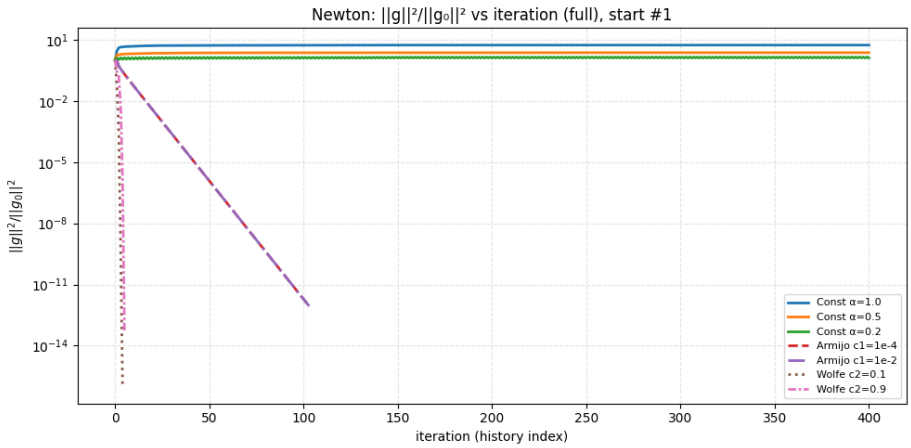

Figure 14: Рис. 1. Ньютон, ML, старт #1, полный график.

Константный шаг за 400 итераций остаётся на «полке» — критерий не выполнен; при $\alpha = 1$ с первой же итерации шаг формально единичный, но последовательность не попадает в малую окрестность решения. Армихо даёт монотонное убывание относительной нормы градиента, но за ≈ 103 итерации. Кривые Вольфа падают за 4–5 итераций.

Рис. 2. Укрупнение: только стратегии без константного шага (Армихо и Вольф), ось k ограничена (в ноутбуке — до 80 итераций или длины самой длинной из этих кривых).

Рис. 3. Выбранные линейным поиском длины шагов α_k по номеру итерации; горизонтальная линия на уровне 1.

У Вольфа после первой–второй итерации шаги стабилизируются у 1; у Армихо и части прогонов — колебания α_k ниже 1 на ранних итерациях.

Старт $w_0 = 21$

Рис. 4–6. Аналогичная тройка графиков для второго старта.

Численно: снова `iterations_exceeded` у констант; Армихо ≈ 102 итерации; Вольф 4–5 итераций. Индекс начала «все $\alpha = 1$» у Вольфа сдвигается (в протоколе — с 1 до 2 для второго старта), что отражает более длинную начальную фазу до попадания в зону, где полный ньютоновский шаг допустим для правил Вольфа.

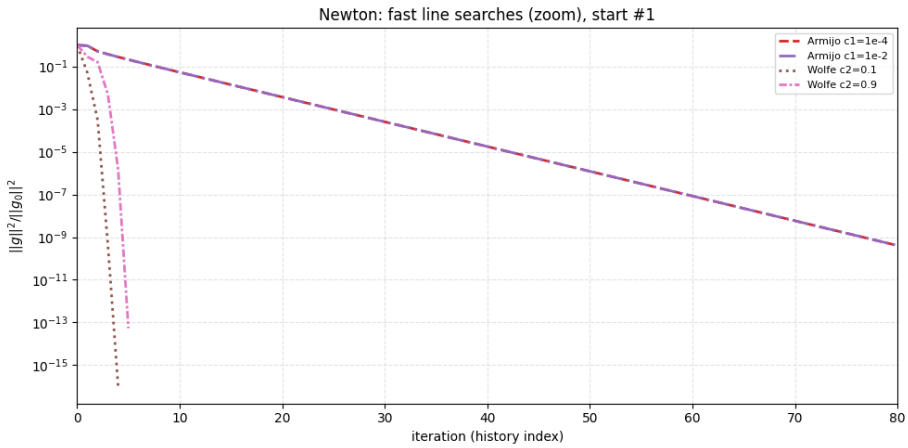

Figure 15: Рис. 2. Ньютон, старт #1, укрупнение.

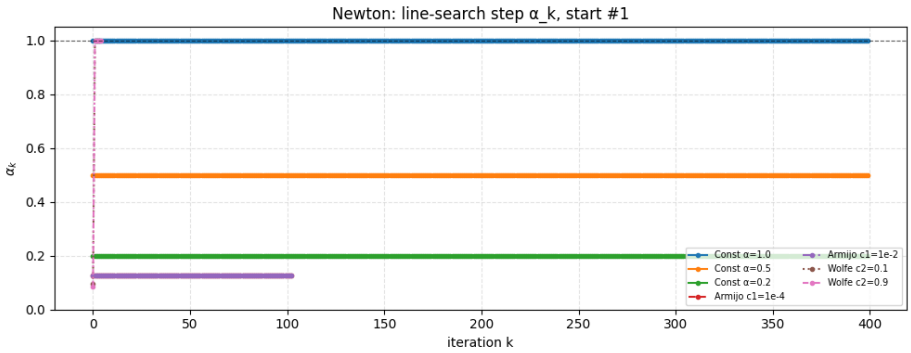

Figure 16: Рис. 3. Ньютон, α_k, старт #1.

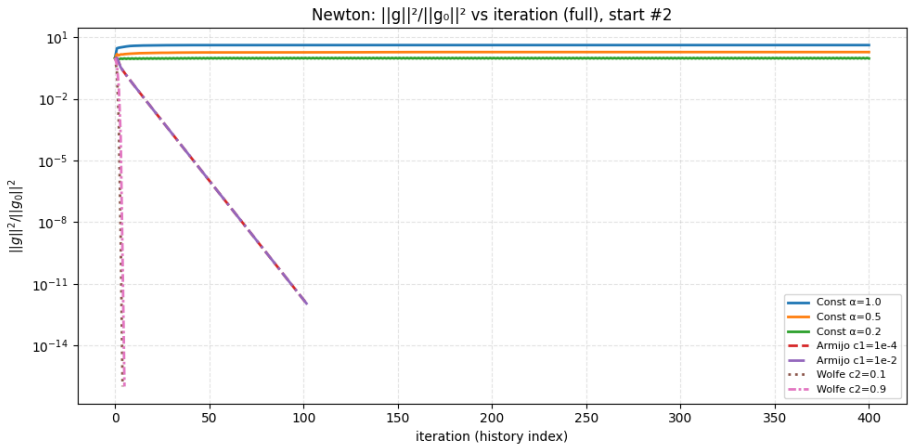

Figure 17: Рис. 4. Ньютон, старт #2, полный график.

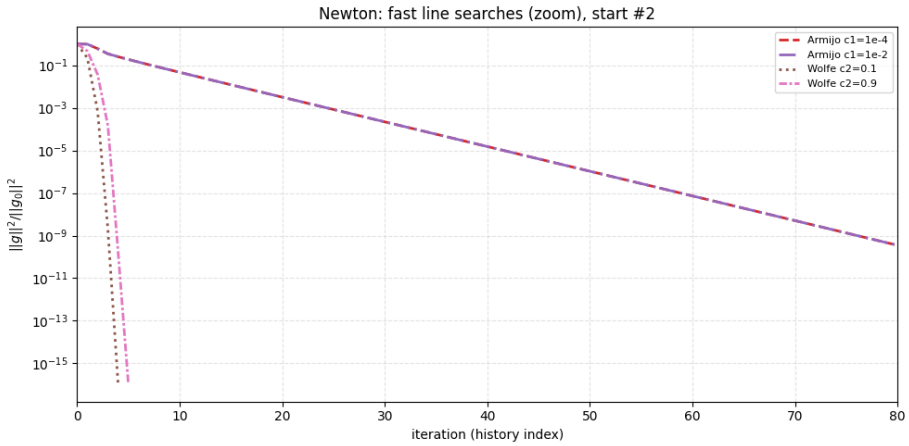

Figure 18: Рис. 5. Ньютон, старт #2, укрупнение.

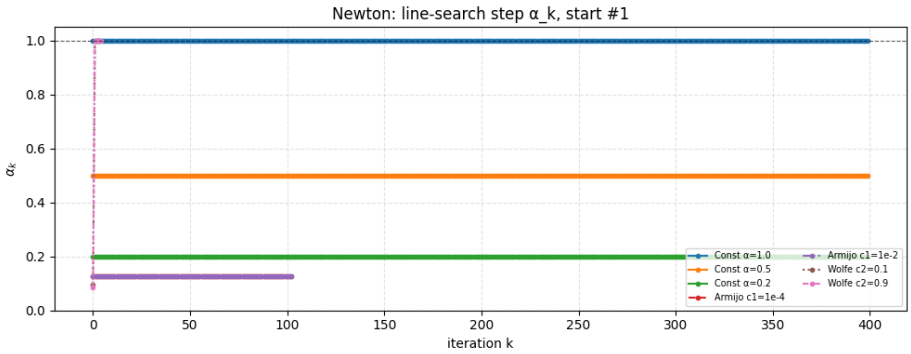

Figure 19: Рис. 6. Ньютон, α_k, старт #2.

г) Выводы и связь с теорией

1. На гладкой выпуклой (строго выпуклой за счёт ridge) задаче регрессии метод Ньютона с Вольфом сочетает быстрое уменьшение градиента с автоматическим переходом к полным шагам у решения, что согласуется с классической картиной локально квадратичной сходимости при SPD-гессиане.

2. Слепой константный шаг $\alpha = 1$ не эквивалентен «правильному» Ньютону без глобализации: из удалённой точки полный шаг может ухудшить целевую функцию и не попасть в область притяжения метода — в эксперименте это проявилось ростом нормы градиента и отсутствием сходимости за фиксированный лимит итераций.

3. Армихо гарантирует спуск и устойчив, но избыточное дробление шага на удалённой фазе замедляет метод по сравнению с Вольфом, который согласован с кривизной вдоль ньютоновского направления и чаще допускает шаги, близкие к единице, уже после первых итераций.

4. На этапе, когда $\alpha_k \equiv 1$, норма градиента резко уменьшается (в численных примерах — вплоть до падения на порядки за один шаг), что соответствует ожидаемому поведению в зоне квадратичной сходимости классического Ньютона.

Задача

Проанализировать зависимость кол-во итераций и время исполнений градиентного спуска и метода ньютона от коэффициента регулязации.

Функции

Log-Cosh Loss

Exponential Loss

Данные

bodyfat для Log-Cosh Loss и gisette для Exponential Loss, точка x_0 генерируется из стандартного нормального распределения.

Метод Ньютона работал слишком долго на gisette, поэтому кол-во параметров было случайным образом уменьшено до 1000

Железо

CPU: Intel i5-12700H

Метод

Градиентный спуск

max_iter=3000 eps=1e-8

Метод Ньютона

max_iter=30 eps=1e-8

Графики

Кол-во итераций градиентного спуска в замисимости от λ

Кол-во итераций метода Ньютона в замисимости от λ

Время работы градиентного спуска в замисимости от λ

Время работы метода Ньютона в замисимости от λ

Норма отимальной точки в градиентном спуске в замисимости от λ

Норма отимальной точки в методе Ньютона в замисимости от λ

Результаты

При стремлении $\lambda \to 0$, кол-во итераций увеличивается. Точнее при $\lambda \to +\inf$, кол-во итераций во всех эксперимантах стремиттся к нулю. Это потому, что при большой регуляции, функция становится похожа на квадратичную, причем с k = 1,

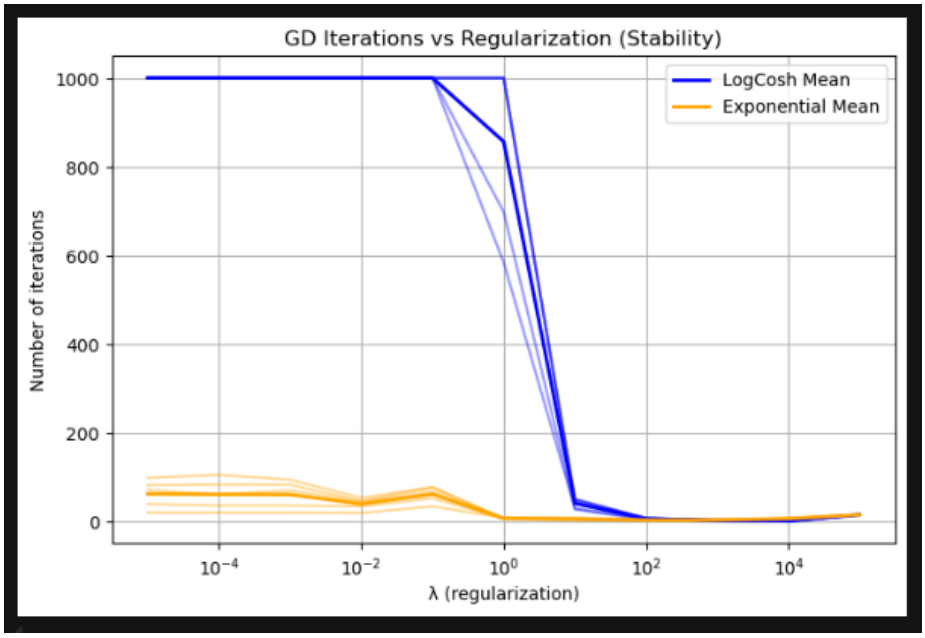

Figure 20: Alt text

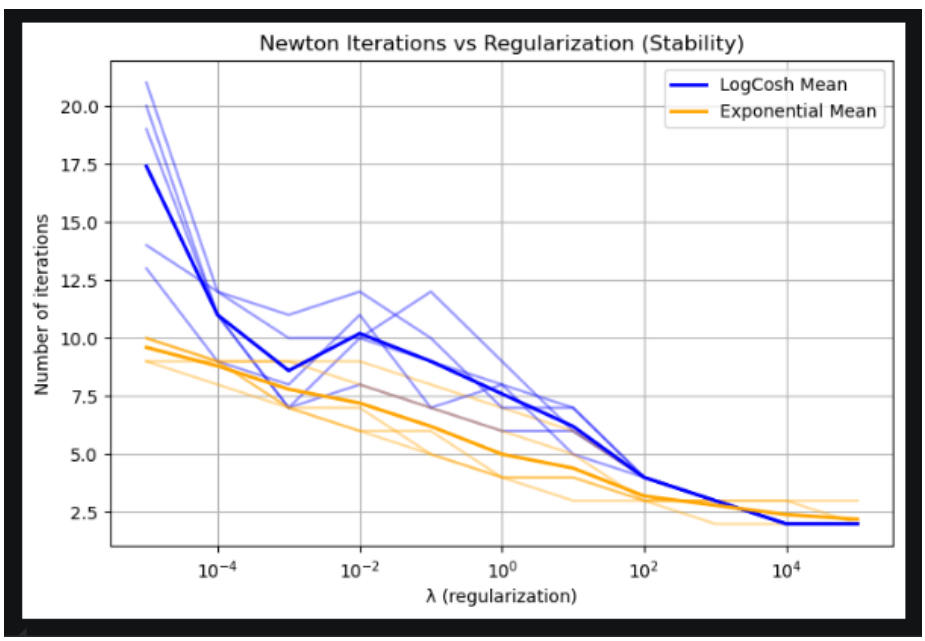

Figure 21: Alt text

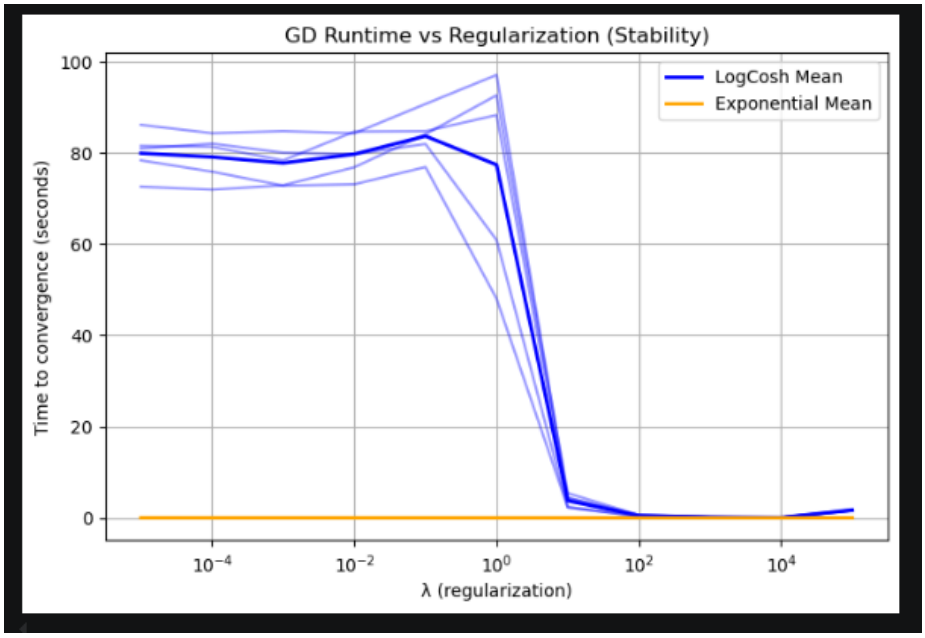

Figure 22: Alt text

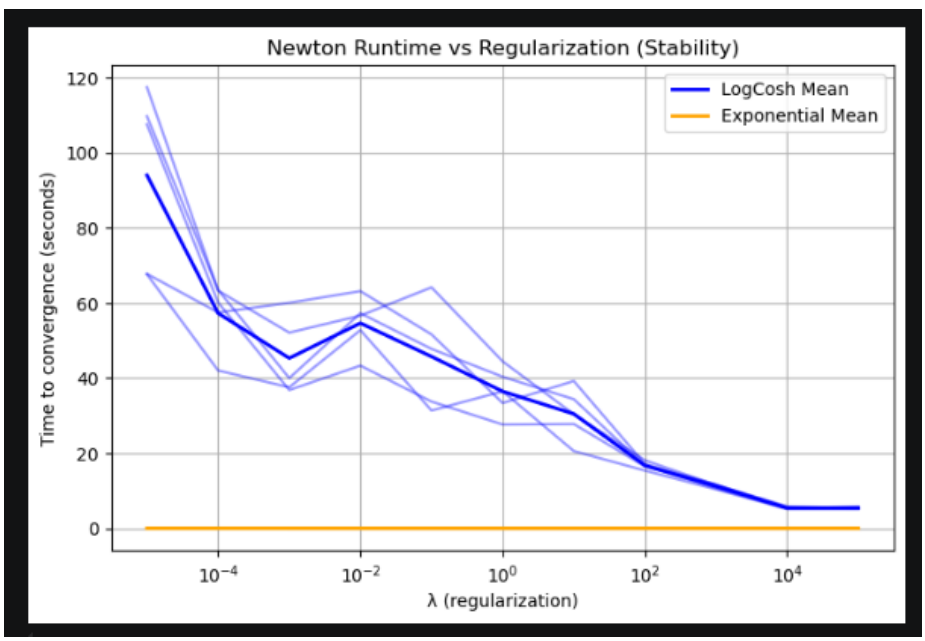

Figure 23: Alt text

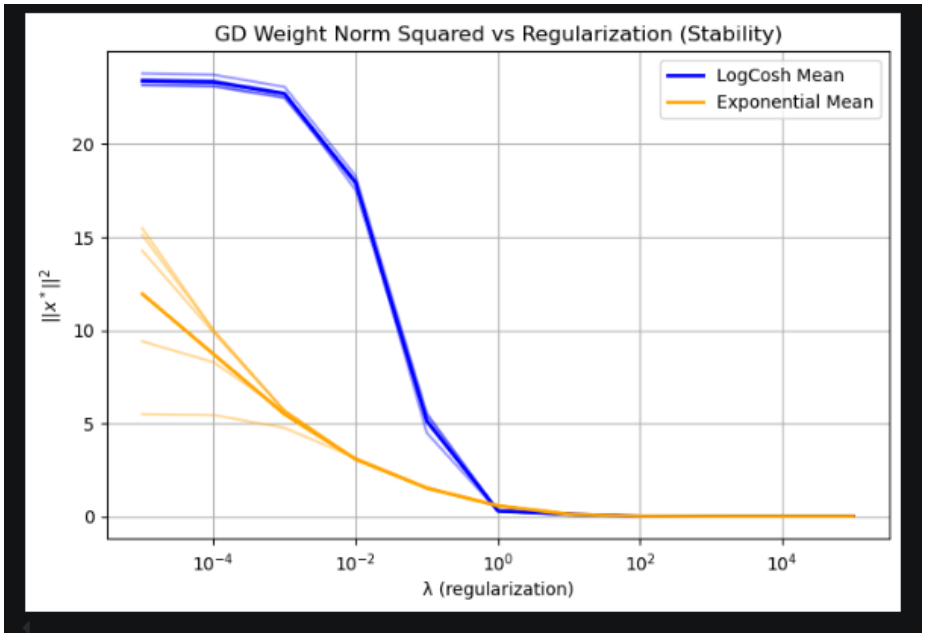

Figure 24: Alt text

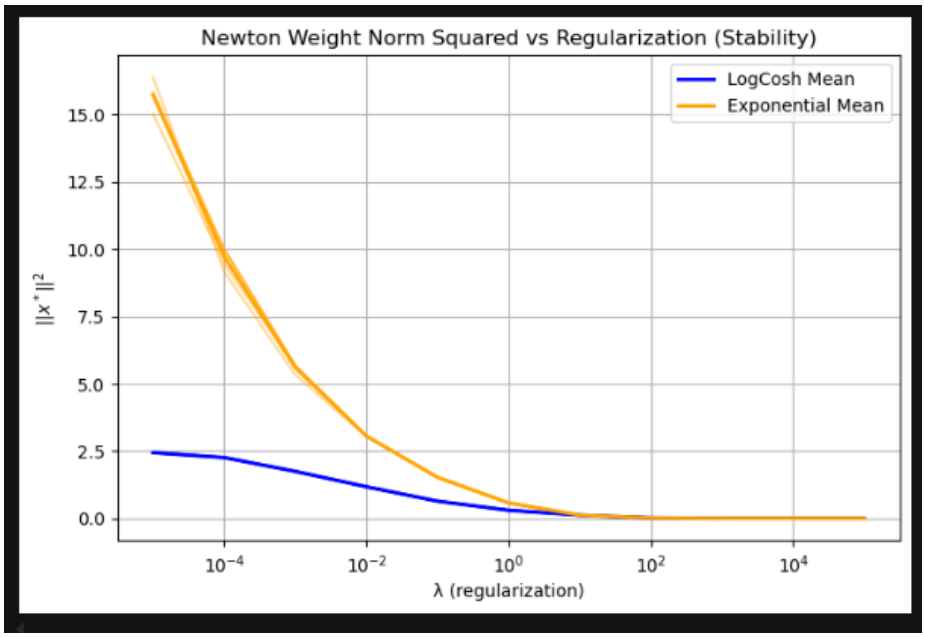

Figure 25: Alt text

а значит: 1) Градиентный спуск будет сходится крайне быстро 2) метод Ньютона бужет крайне быстро находить минимум, потому что модель параболы, которую он создает будет очень точна

Численная неустойчивость возникала при малый λ, но не сильная. При малых λ, траектории методов почти неизменяются, так что эти неустойчивости остались от методов.

При больших λ у градиентного спуска явно видно плато. Это можно объяснить, во-первых, из-за того, что итераций и так уже мало, во вторых, функция приближается к идеальной: квадратичная с $k = 1$. У метода Ньютона нет плато, но если посмотреть внимательно, то можно увидеть, что при $\lambda = 1e5$ он сходится за 2 итерации (одна из них - начальная), т.е. он сразу находит минимум, а значит если увеличить λ, то мы увидим плато, просто потому меньше итераций просто не сделать

При увеличении λ, зона квадратичной сходимости растет, т.к. функция становится более обусловленной

Задача

Исследовать эвристические модификации метода Ньютона

Функции

Функция Билла

Exponential Loss

Данные

gisette для Exponential Loss, точка $x_0 = 0_n$

Метод Ньютона работал слишком долго на gisette, поэтому кол-во параметров было случайным образом уменьшено до 1000

Железо

CPU: Intel i5-12700H

Метод

Метод Ньютона

Результаты

Иногда shift метод находит оптимум, а spectral метод не находит.

Траектории из разных начальных точек. Функция Билла

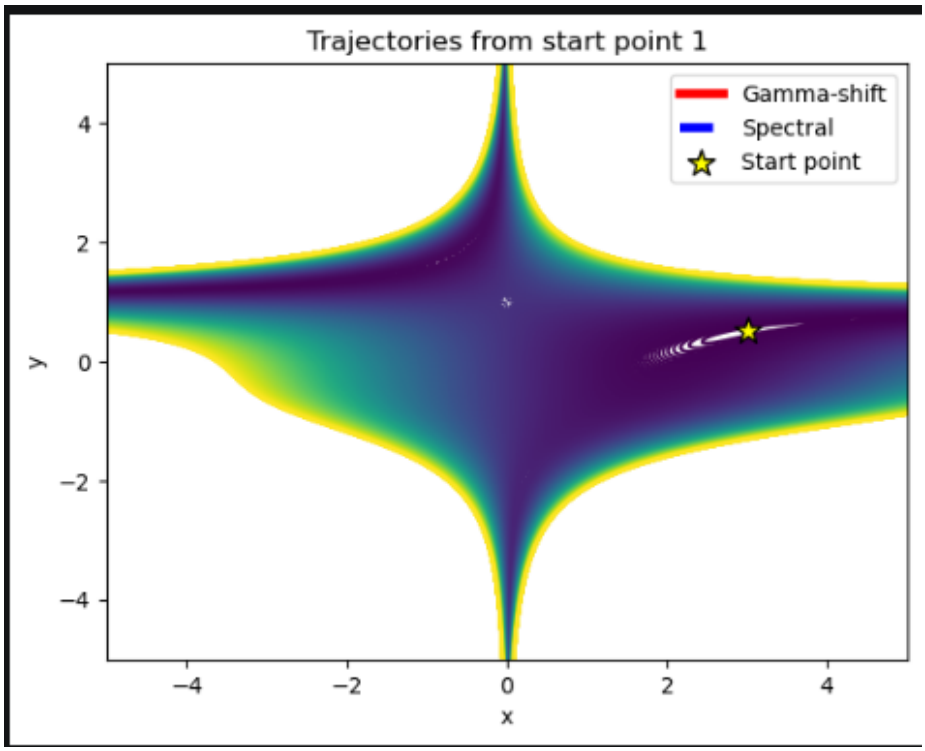

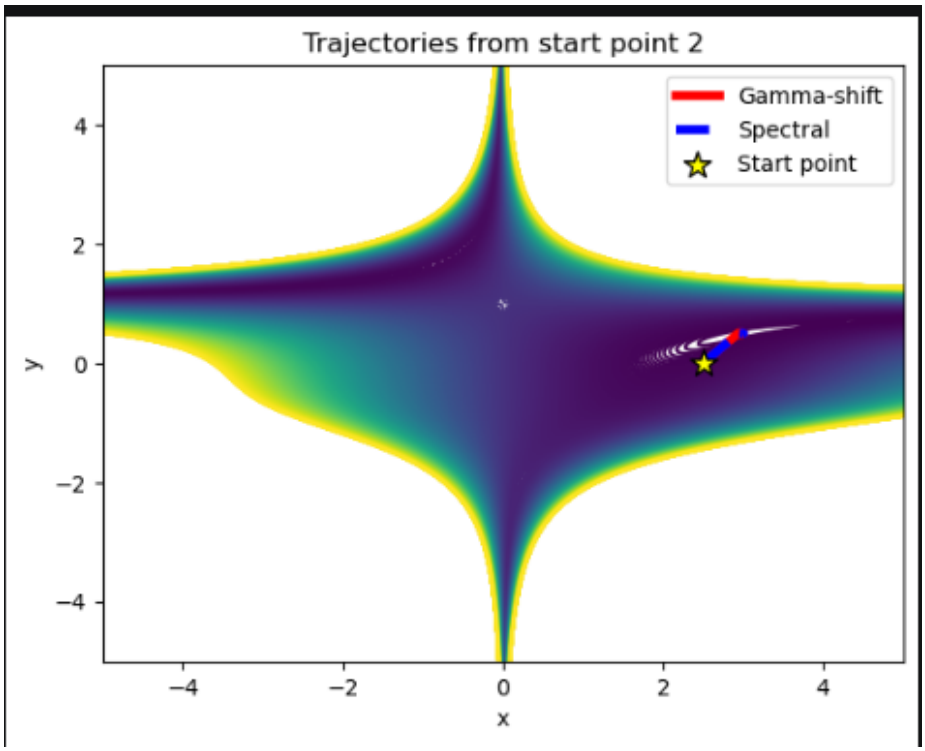
Trajectories from start point 2
Gamma-shift
Spectral
Start point
4
2
0
−2
−4
y
−4
−2
0
2
4
x

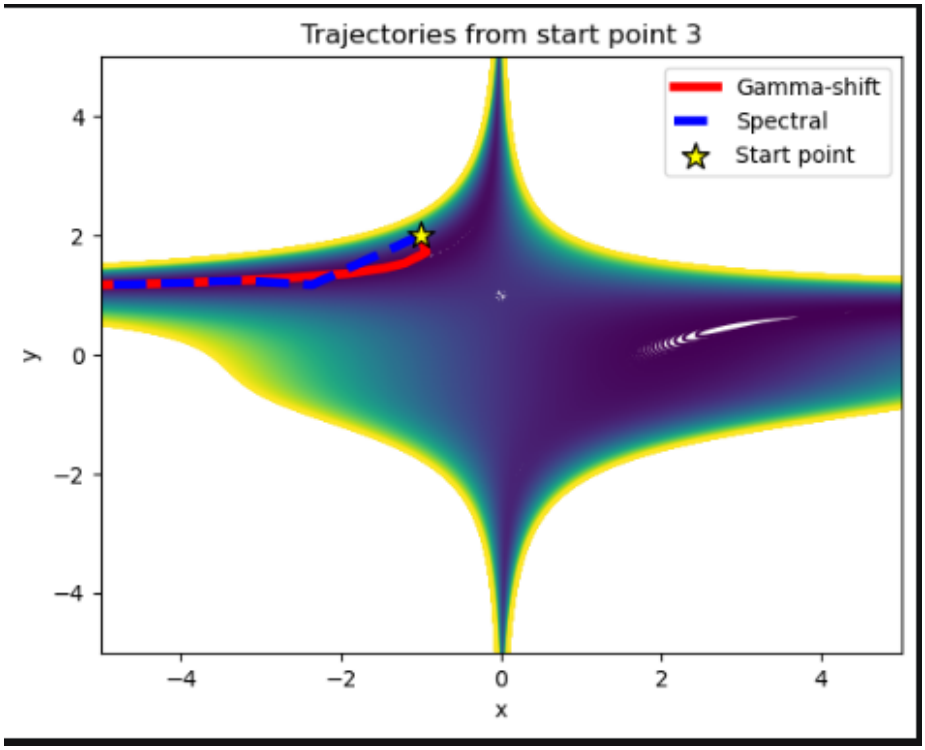
Trajectories from start point 3
Gamma-shift
Spectral
Start point
4
2
0
−2
−4
y
−4
−2
0
2
4
x

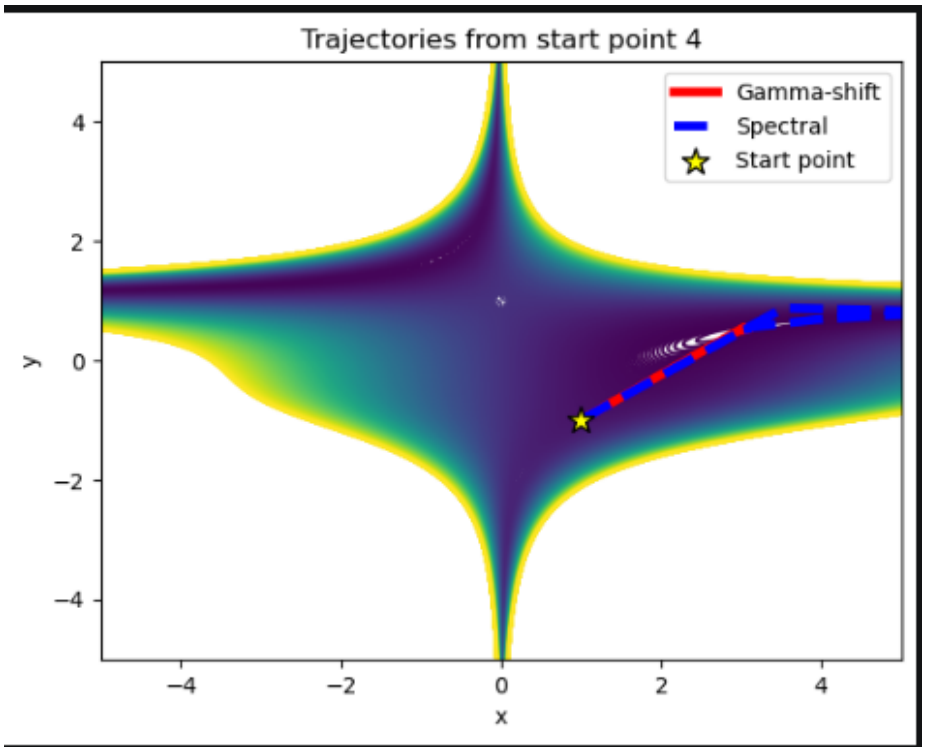
Trajectories from start point 4
Gamma-shift
Spectral
Start point
4
2
0
−2
−4
y
−4
−2
0
2
4
x

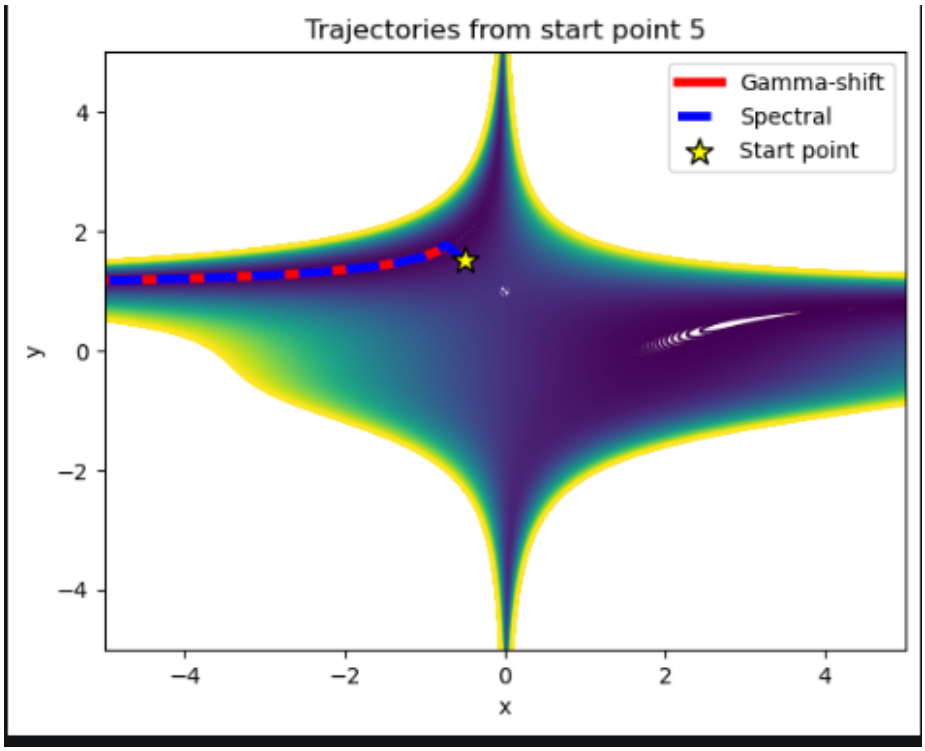
Trajectories from start point 5
Gamma-shift
Spectral
Start point
4
2
0
−2
−4
y
−4
−2
0
2
4
x

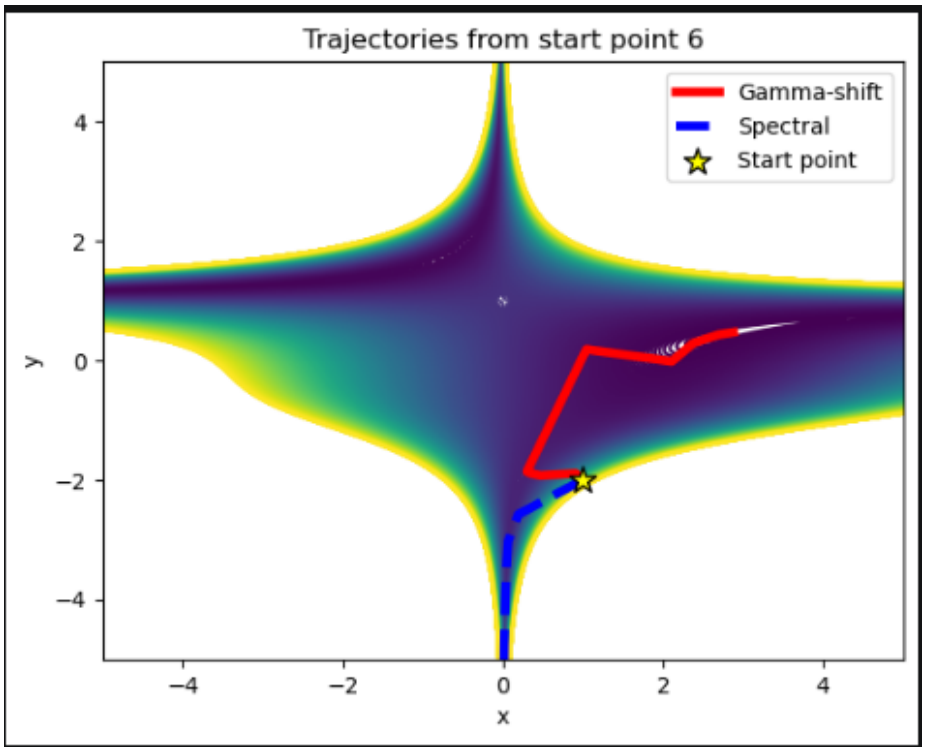
Trajectories from start point 6
Gamma-shift
Spectral
Start point
4
2
0
−2
−4
y
−4
−2
0
2
4
x

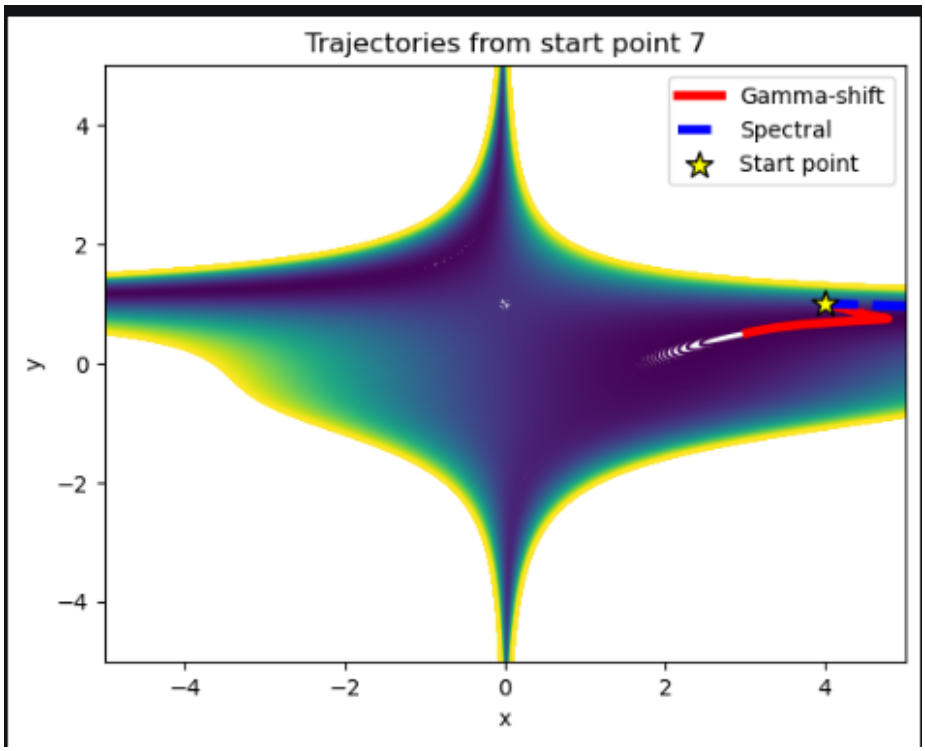
Trajectories from start point 7
Gamma-shift
Spectral
Start point
4
2
0
−2
−4
y
−4
−2
0
2
4
x

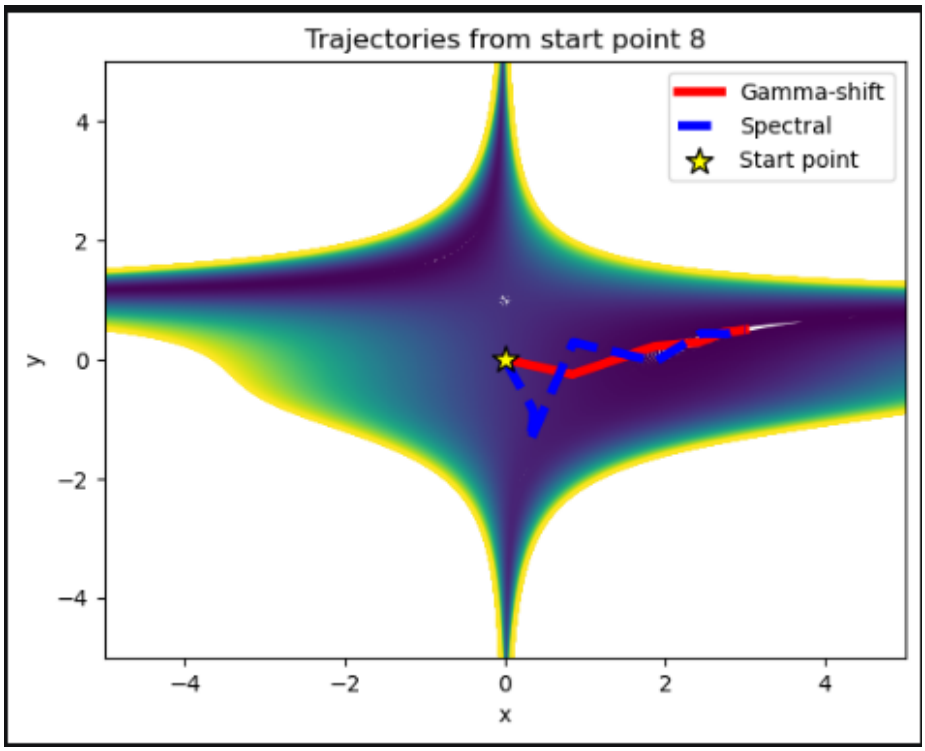
Trajectories from start point 8
Gamma-shift
Spectral
Start point
4
2
0
−2
−4
y
−4
−2
0
2
4
x

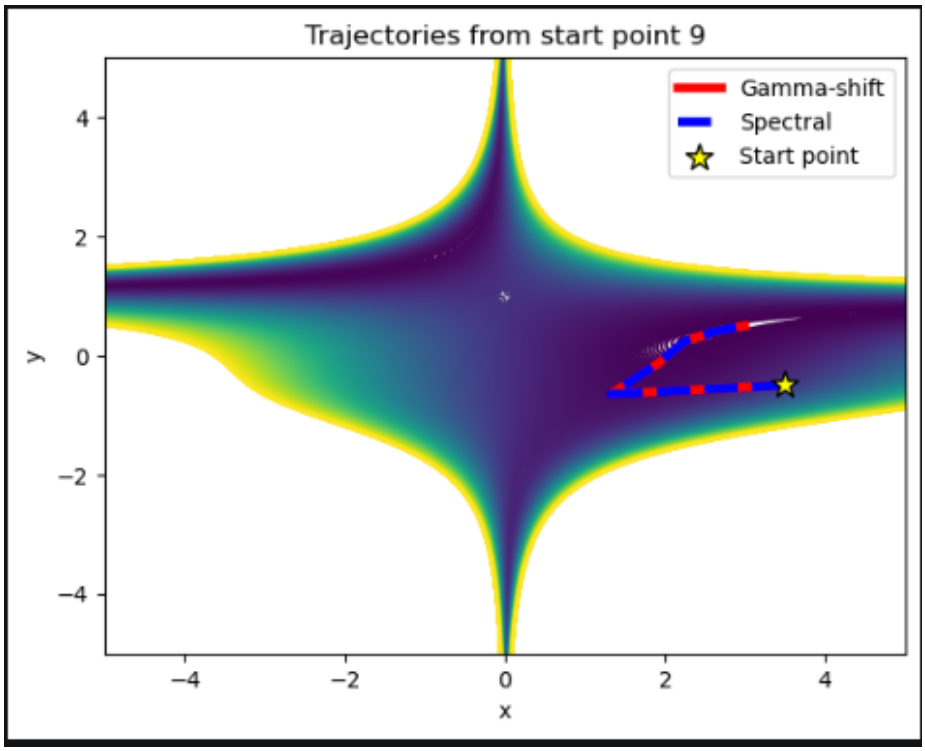
Trajectories from start point 9
Gamma-shift
Spectral
Start point
4
2
0
−2
−4
y
−4
−2
0
2
4
x

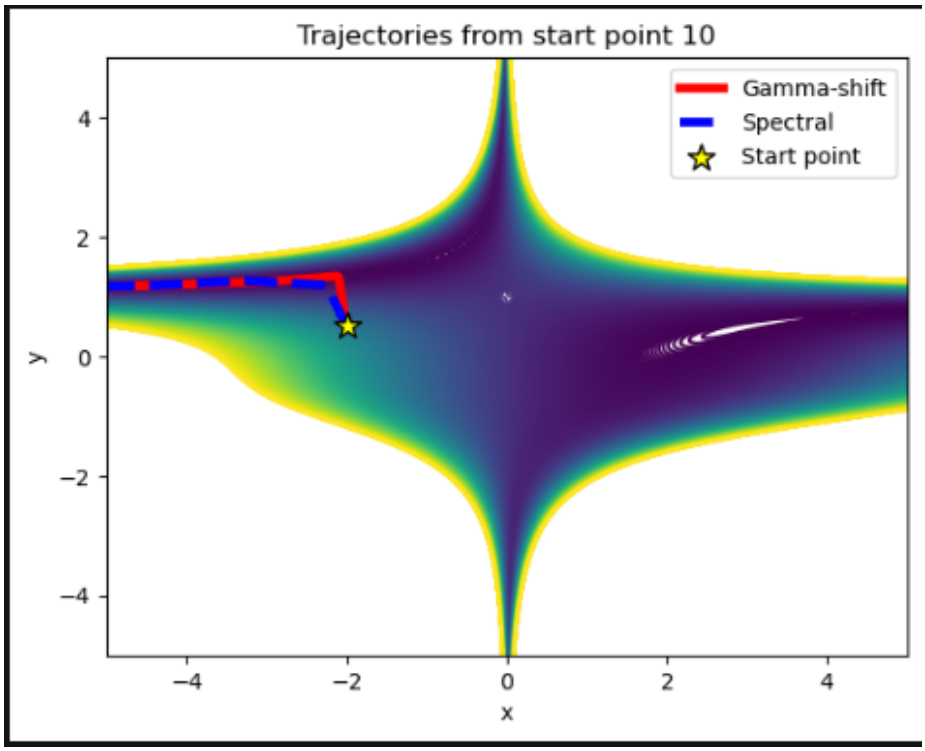

График изменения γ

Можно увидеть, что оно очень быстро уменьшается

Вот геометрическое обоснование, что shift метод при большом γ ведет себя как градиентный спуск, а спектральное усечение сохраняет “нью-тоновское”поведение вдоль осей положительной кривизны.

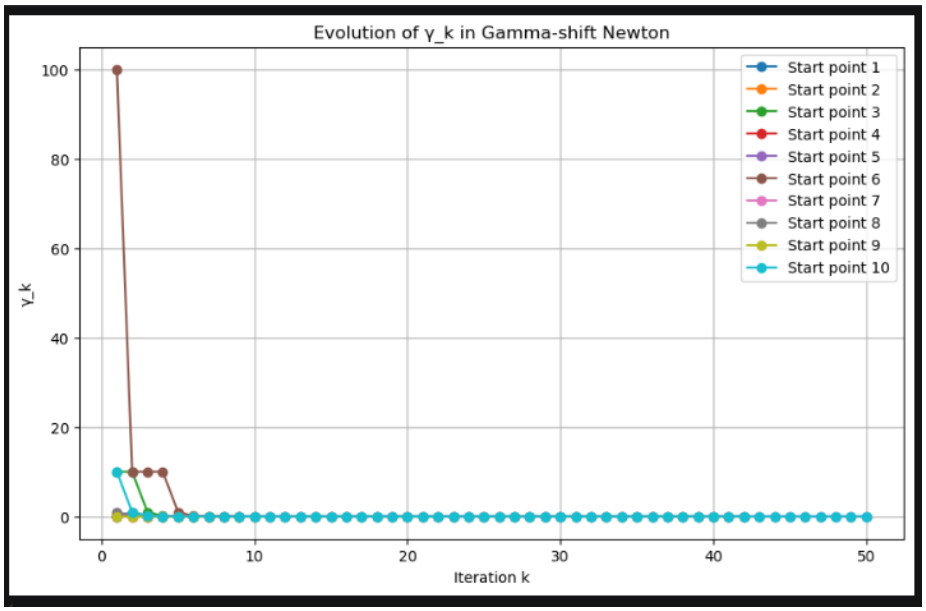

Figure 26: Alt text

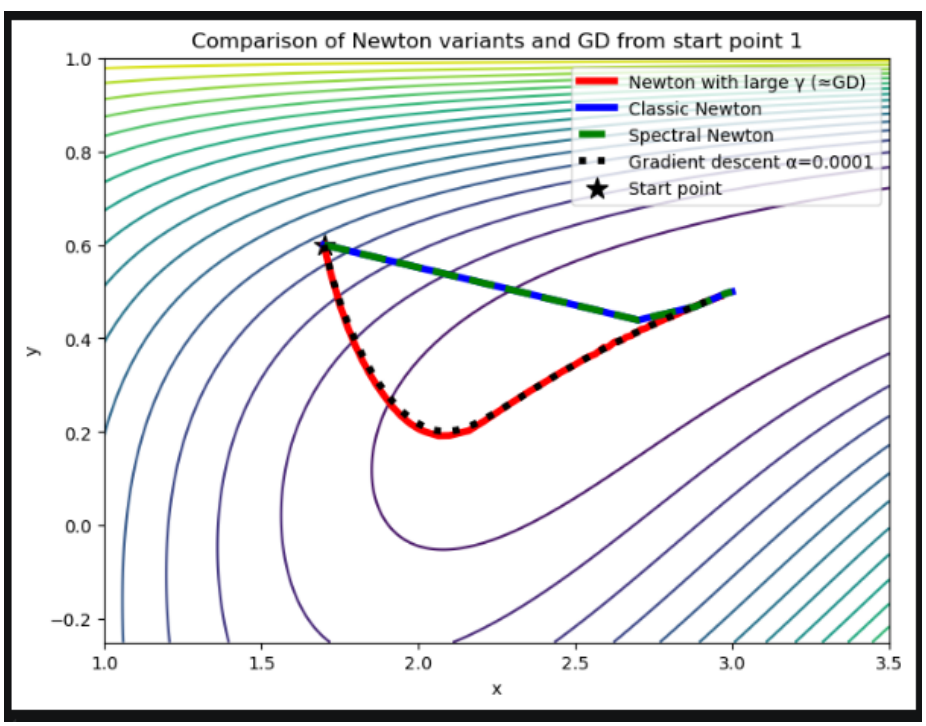

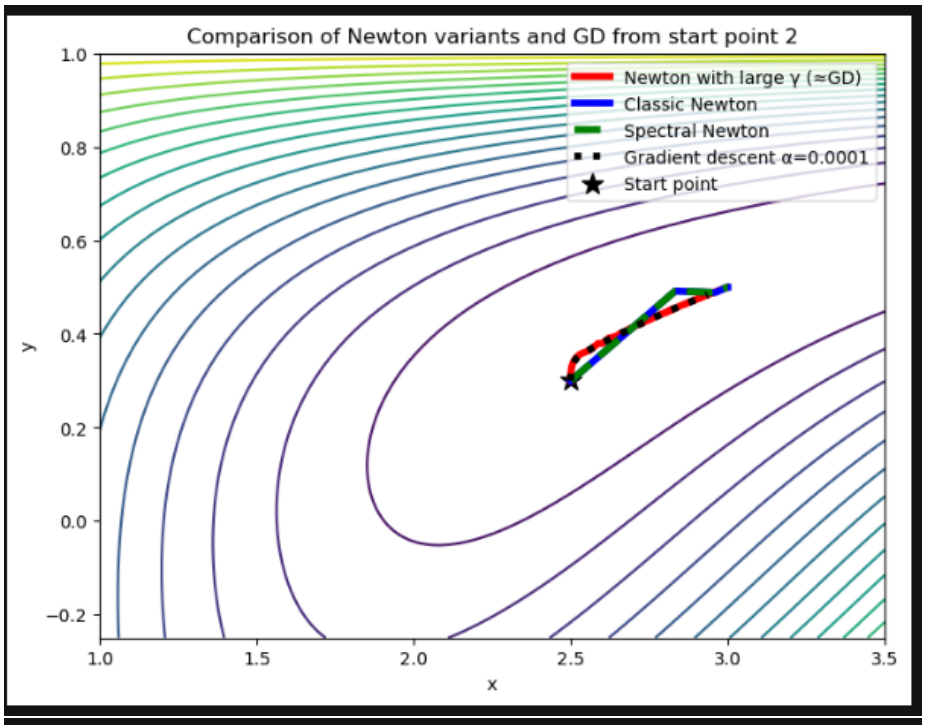
Comparison of Newton variants and GD from start point 2
Newton with large γ (≈GD)
Classic Newton
Spectral Newton
Gradient descent α=0.0001
Start point
x
y

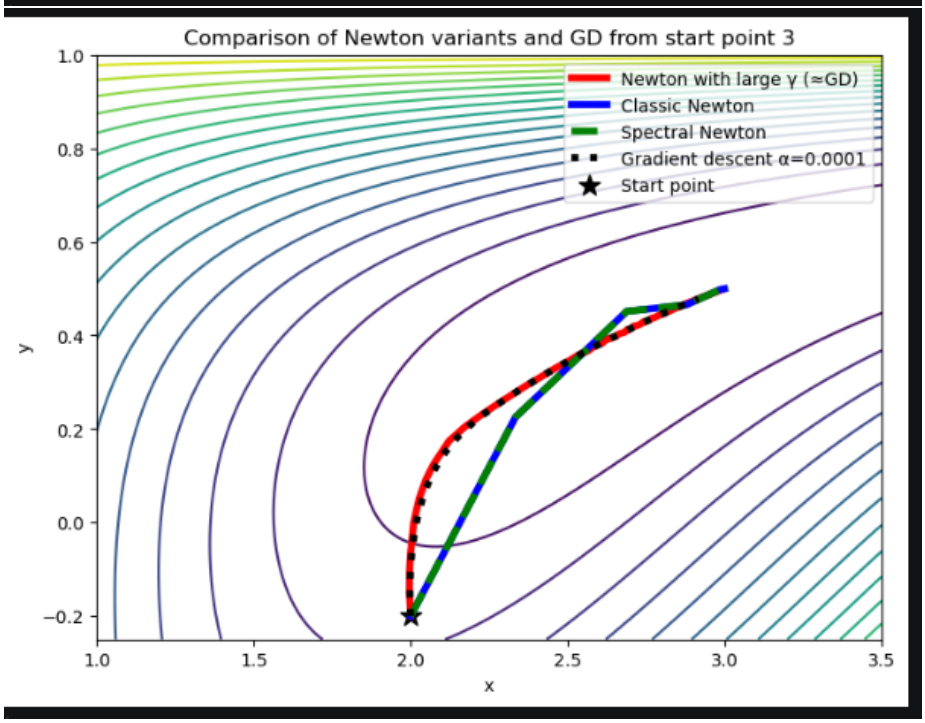
Comparison of Newton variants and GD from start point 3
Newton with large γ (≈GD)
Classic Newton
Spectral Newton
Gradient descent α=0.0001
Start point
x
y

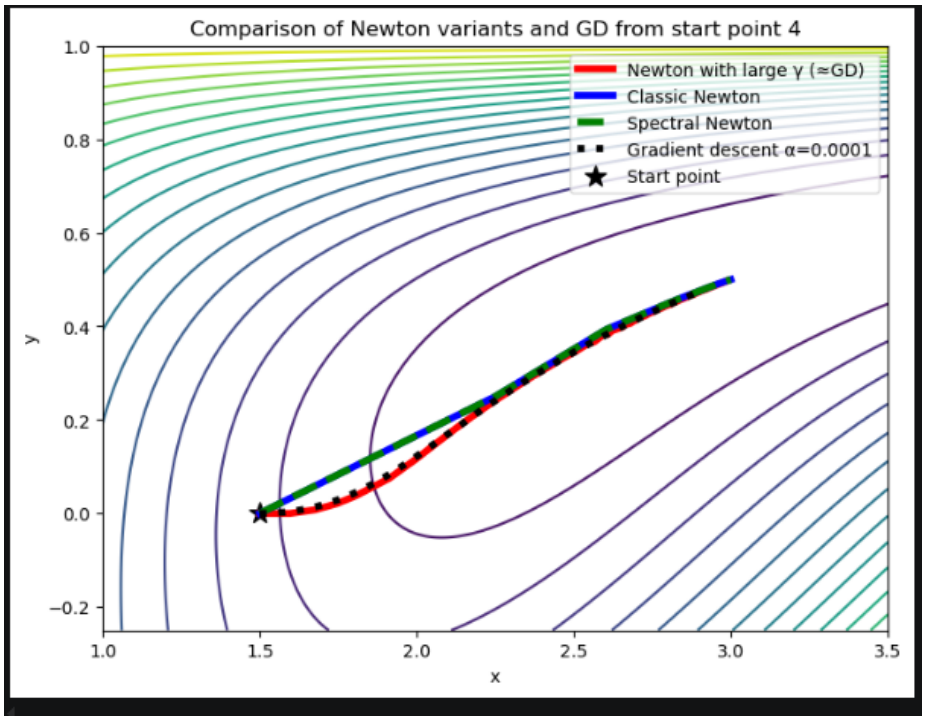

Вот сравнение скорости методов. ExponentialLoss, gisette

Методы работают примерно с такой же скоростью. Разве что shift метод немног быстрее, видимо, из-за более обусловленной матрицы

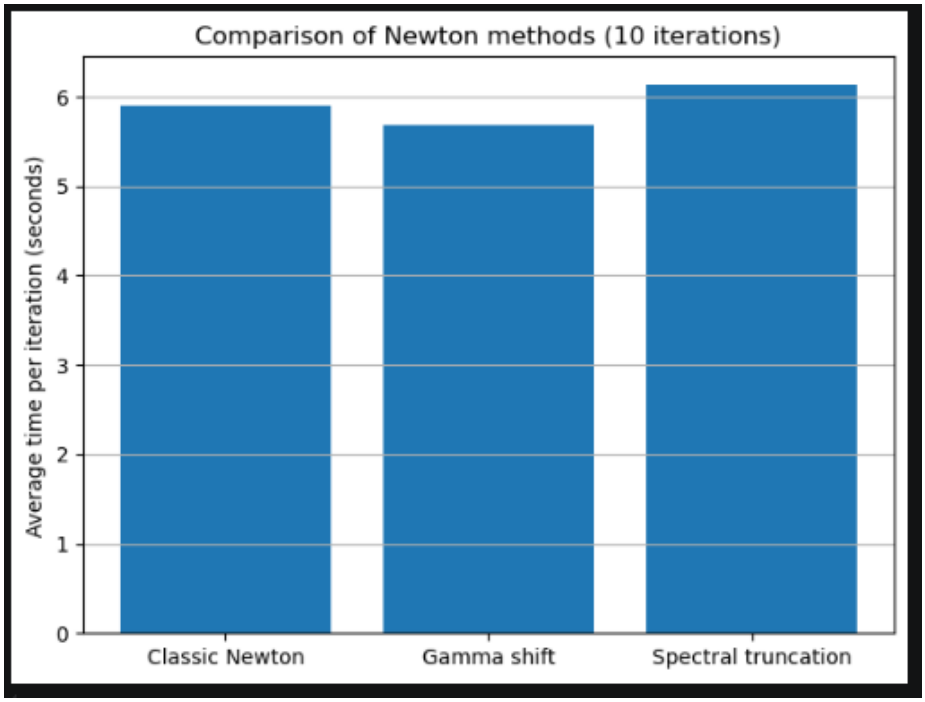

Figure 27: Alt text